

**Desarrollo de un sistema de información para el análisis comparativo y predictivo de la
evolución de competencias académicas entre las pruebas Saber 11 y Saber Pro - Caso
Universidad San Buenaventura**

Jostin Alejandro Gómez Restrepo
Samuel Giraldo Duque

Trabajo de Grado presentado para optar al título de Ing. Datos y software

Asesor:
Jairo Ivan Coy Coy



Universidad de San Buenaventura
Facultad de Ingenierías (Bello)
Ingeniería Datos y software
Bello, Colombia
2026

Citar/How to cite	González Mejía et al . [1]
Referencia/Reference	[1] J. Gómez Restrepo S. Giraldo Duque . “Desarrollo de un sistema de información para el análisis comparativo y predictivo de la evolución de competencias académicas entre las pruebas Saber 11 y Saber Pro - Caso Universidad San Buenaventura ”, Trabajo de grado profesional , Ingeniería Datos y software , Universidad de San Buenaventura Bello, Colombia , 2026 .
Estilo/Style: IEEE (2014)	



En convenio con la Universidad (nombre y logo pequeño de la institución).
 Seleccione posgrado USB Colombia (A-Z), Cohorte X.
 Grupo de Investigación (SIGLA).
 Línea de investigación en.



Biblioteca Digital (Repositorio)
www.bibliotecadigital.usb.edu.co

Bibliotecas Universidad de San Buenaventura

Biblioteca Fray Alberto Montealegre O.F.M. - Bogotá.
 Biblioteca Fray Arturo Calle Restrepo O.F.M. - Medellín, Bello, Armenia, Ibagué.
 Departamento de Biblioteca - Cali.
 Biblioteca Central Fray Antonio de Marchena – Cartagena.

Universidad de San Buenaventura Colombia - www.usb.edu.co

Bogotá - www.usbbog.edu.co

Medellín - www.usbmed.edu.co

Cali - www.usbcali.edu.co

Cartagena - www.usbctg.edu.co

Editorial Bonaventuriana - www.editorialbonaventuriana.usb.edu.co

Revistas científicas – www.revistas.usb.edu.co

Dedicatoria

Texto de dedicatoria centrado.

Agradecimientos

Texto de agradecimientos centrado.

TABLA DE CONTENIDO

RESUMEN	8
ABSTRACT	9
I INTRODUCCIÓN	10
II PLANTEAMIENTO DEL PROBLEMA	11
III ANTECEDENTES	12
IV JUSTIFICACIÓN	14
V OBJETIVOS	15
A Objetivo General	15
B Objetivos Específicos	15
VI PROBLEMA DE INVESTIGACIÓN	16
VII HIPÓTESIS	17
VIII MARCO REFERENCIAL	18
A Marco Teórico	18
B Marco Conceptual	18
C Estado del Arte	22
IX METODOLOGÍA	24
A Recolección e integración de datos	24
B Depuración y tratamiento de registros atípicos	24
C Correspondencia de competencias y cálculo del puntaje global	25
D Normalización y escalado	26
E Partición temporal	26
F Sistema de formas y variables de entrada	27
G Arquitectura y entrenamiento del modelo de valor agregado	27
H Evaluación y despliegue del sistema	29
X RESULTADOS	30
A Desempeño predictivo de los modelos	30

B	Valor agregado institucional	30
XI	DISCUSIÓN	32
XII	CONCLUSIONES	34
XIII	RECOMENDACIONES	35
XIV	ANEXOS	36
A	Diccionario de datos	36
B	Manual técnico	36
C	Capturas del tablero interactivo	36
XV	REFERENCIAS	40

LISTA DE TABLAS

1	Tabla de correspondencia de pares análogos entre Saber 11 y Saber Pro.	26
2	R^2 en el conjunto de prueba por modelo y competencia (Forma 1 / Forma 2). . . .	30
3	Aporte institucional (valor agregado) por competencia y año.	31

LISTA DE FIGURAS

1	Menú de login.	36
2	Página de inicio.	37
3	Menú de resumen.	37
4	Menú de comparativa para puntajes entre universidades.	38
5	Menú para generar reportes en PDF.	38
6	Tablas de la base de datos.	39

RESUMEN

El presente trabajo desarrolla un sistema de información para el análisis comparativo y predictivo de la evolución de competencias académicas entre las pruebas Saber 11 y Saber Pro. A partir de aproximadamente 1,32 millones de pares de estudiantes emparejados a nivel individual, se integraron ambas pruebas en una base de datos relacional y se construyó un modelo de valor agregado cuyo motor predictivo es una red neuronal artificial de tipo perceptrón multicapa, contrastada frente a modelos de referencia de regresión lineal y de segmentación K-means. La estimación se abordó bajo dos configuraciones de entrada, con y sin variables socioeconómicas, con el fin de cuantificar el aporte del contexto. Los resultados muestran una capacidad explicativa moderada (R^2 entre 0,39 y 0,61), en la que la red neuronal supera a los modelos de referencia salvo en Inglés, y un valor agregado institucional mayoritariamente negativo. Estos hallazgos no confirman la hipótesis inicial, pero el sistema desarrollado cumple su función analítica y se materializa en un tablero interactivo de apoyo a la toma de decisiones institucionales.

***Palabras clave* — valor agregado educativo, Saber 11, Saber Pro, redes neuronales artificiales, sistema de información**

ABSTRACT

This work develops an information system for the comparative and predictive analysis of the evolution of academic competencies between the Saber 11 and Saber Pro tests at Universidad de San Buenaventura. Based on approximately 1.32 million individually matched student pairs, both tests were integrated into a relational database, and a value-added model was built whose predictive engine is an artificial neural network of the multilayer perceptron type, benchmarked against linear regression and K-means segmentation reference models. The estimation was carried out under two input configurations, with and without socioeconomic variables, in order to quantify the contribution of context. The results show a moderate explanatory capacity (R^2 between 0.39 and 0.61), in which the neural network outperforms the reference models except in English, and a predominantly negative institutional value added. These findings do not confirm the initial hypothesis, yet the developed system fulfills its analytical purpose and materializes in an interactive dashboard supporting institutional decision-making.

Keywords — educational value added, Saber 11, Saber Pro, artificial neural networks, information system

I. INTRODUCCIÓN

La calidad de la educación superior en Colombia constituye un tema de creciente interés institucional y académico, especialmente en lo que respecta a la medición objetiva del desarrollo de competencias a lo largo del proceso formativo. En este contexto, el Instituto Colombiano para la Evaluación de la Educación (ICFES) administra dos instrumentos estandarizados de gran relevancia: la prueba Saber 11, aplicada al finalizar la educación media, y la prueba Saber Pro, aplicada al término de la formación universitaria. Ambas pruebas permiten evaluar habilidades cognitivas y competencias en distintos momentos del ciclo educativo, lo que las convierte en una fuente de información valiosa para estudiar la evolución académica del estudiante. Sin embargo, a pesar de la riqueza informativa que ofrecen estos instrumentos, son pocas las instituciones de educación superior que han aprovechado sistemáticamente los datos generados por ambas pruebas para construir modelos analíticos que permitan comparar el desempeño inicial y final de sus estudiantes, identificar tendencias de crecimiento o estancamiento, y orientar estrategias educativas basadas en evidencia. La Universidad de San Buenaventura no es ajena a esta situación, lo que representa una oportunidad significativa para transformar datos académicos históricos en conocimiento institucional útil. Ante esta necesidad, el presente trabajo de grado propone el desarrollo de un sistema de información predictivo y comparativo que examine la evolución de las competencias académicas de los estudiantes desde las pruebas Saber 11 hasta las Saber Pro. Para ello, se integrará información proveniente de ambas pruebas junto con variables contextuales y socioeconómicas relevantes, con el fin de construir modelos estadísticos y de aprendizaje automático que estimen el desempeño esperado y permitan cuantificar el valor agregado que la institución aporta al proceso formativo de sus estudiantes. Desde el campo de la ingeniería de datos y bajo este argumento, este proyecto representa una aplicación concreta de técnicas de minería de datos educativos (*Educational Data Mining*, EDM), análisis estadístico, visualización interactiva al ámbito de la gestión académica universitaria y la integración de modelos basados en sistemas inteligentes. El uso de algoritmos como la regresión lineal, los árboles de decisión y el método de los k vecinos más cercanos (KNN) permitirá construir modelos robustos de predicción, mientras que los tableros de control (*dashboards*) facilitarán la interpretación de resultados por parte de los tomadores de decisiones institucionales.

II. PLANTEAMIENTO DEL PROBLEMA

El seguimiento del progreso académico de los estudiantes a lo largo de su formación universitaria constituye una herramienta clave para medir la calidad educativa y orientar estrategias de mejora continua. Sin embargo, existe una oportunidad de mejora basada en los datos que cada universidad recolecta de las pruebas Saber 11 y Saber Pro que no es comúnmente aprovechada, y que consiste en tomar toda esta información y transformarla en decisiones de negocio que se reflejen en mejores resultados académicos en los estudiantes. Esta situación surge dado que la mayoría de las instituciones de educación superior no disponen de sistemas que integren y analicen de manera estructurada la información proveniente de la prueba Saber Pro y se alíe con instituciones escolares que les proporcione información sobre los resultados de las pruebas Saber 11 recientes. A su vez, esta falta de integración impide realizar análisis comparativos que permitan evaluar la evolución de las competencias adquiridas durante el proceso de formación [8]. En el caso de la Universidad San Buenaventura, donde todavía se cuenta con esta falencia, se muestra como una oportunidad de mejora, contar con un sistema de información que relacione los resultados de ambas pruebas facilitando la identificación de patrones de aprendizaje, fortalezas institucionales y áreas de oportunidad para cada programa académico [9]. La ausencia de este tipo de herramientas limita la capacidad de realizar predicciones sobre el rendimiento futuro de los estudiantes y restringe la generación de estrategias pedagógicas basadas en evidencia [5]. Por lo tanto, se presenta la necesidad de desarrollar un sistema que consolide los datos de las pruebas Saber Pro, que incorpore técnicas estadísticas y modelos predictivos permitiendo anticipar la fluctuación de las competencias académicas a lo largo del proceso educativo.

III. ANTECEDENTES

Los factores estructurales y contextuales que tienen incidencia en los puntajes de las pruebas Saber 11 han sido estudiados en la literatura colombiana, lo que permite fundamentar qué debe capturar un sistema de información que busque realizar un análisis comparativo y predictivo con robustez. Uno de los estudios más citados es el que realizó [1], en el año 2010, donde mediante un modelo Logit Ordenado generalizado se encontraron impactos positivos y significativos de variables como nivel de ingreso del hogar, escolaridad de los padres, tipo de jornada escolar y naturaleza del colegio (oficial vs. no oficial) sobre los puntajes en matemáticas y lenguaje. El estudio de [2], en el año 2024, encontró que los puntajes bajos se asocian sistemáticamente con carencia de recursos educativos, bajo nivel educativo de los padres y condiciones de vida menos favorables, mientras que los puntajes altos se relacionan con mayores ingresos y mejores entornos familiares. En el Atlántico, la investigación realizada por [3], en el año 2022, aplicó análisis demográficos, sociales y económicos para identificar variables determinantes del rendimiento en Saber 11, tales como el acceso a internet, características del colegio y variables socioeconómicas del estudiante. Otro estudio regional, realizado por [4], en el año 2018, encontró que el ingreso del hogar, el estrato socioeconómico y la educación de los padres tienen efectos estadísticamente significativos sobre el puntaje en Saber 11, y que la educación de los padres contribuye de forma similar y consistente al rendimiento académico del hijo. Adicionalmente, el informe nacional del ICFES del año 2023, [5], presenta análisis de efectos marginales en modelos estadísticos que muestran cómo factores económicos, familiares y escolares inciden en los resultados del examen Saber 11 a nivel nacional, incluyendo variables como la condición de población víctima del conflicto armado, lo que permite dimensionar desigualdades territoriales y sociales. Por su parte, [6] en el año 2011, documenta que los estudiantes pertenecientes a etnias como indígena, afrocolombiana, raizal y rom, obtienen en promedio puntajes inferiores, y que aunque parte de esa brecha se explica por características observables (familiares, institucionales y sociales), otra parte se debe a factores no observados, lo que implica que el sistema debe contemplar variables latentes o de contexto para capturar esta variación. Finalmente, el estudio realizado por [7], del año 2012, estudia múltiples grupos de variables independientes —demográficas, socioeconómicas, familiares, escolares e institucionales— y encuentra que la zona y condición de trabajo, pertenecer a una etnia, la pérdida de grados, el tipo de colegio, la jornada escolar y el acceso a internet son determinantes significativos del desempeño destacado frente al no destacado. Estos antecedentes muestran que los factores que consistentemente aparecen asociados al rendimiento en Saber 11 incluyen: nivel socioeconómico, ingresos económicos del hogar, escolaridad de los padres, tipo de colegio (oficial/privado), jornada escolar, acceso a recursos como internet o computadores, etnia, pérdida de grados, así como diferencias regionales y contextuales. Para el sistema propuesto, esto

implica que debe diseñarse para recolectar, limpiar e integrar estas variables, asegurar que los datos sean representativos (territorialidad, diversidad de programas, etc.) e incorporar métodos de modelado que permitan comparar subgrupos, estimar efectos marginales y posiblemente identificar variables no observadas o proxies que reflejen el contexto institucional. De esta manera, se podrán lograr predicciones útiles y, sobre todo, crear y diseñar estrategias institucionales orientadas a fortalecer las competencias académicas de los estudiantes.

IV. JUSTIFICACIÓN

La implementación de un sistema de información predictivo y comparativo permitirá optimizar el análisis del desempeño académico institucional [10]. Este proyecto no solo busca integrar la información proveniente de las pruebas Saber 11 y Saber Pro, sino también generar una herramienta que apoye la evaluación de la evolución formativa del estudiante desde su ingreso hasta la culminación de su carrera. Con este desarrollo, la Universidad San Buenaventura podrá identificar tendencias de crecimiento o estancamiento en las competencias, determinar qué factores inciden en el desempeño académico y orientar sus estrategias educativas hacia una mejora continua. Adicionalmente, el uso de técnicas estadísticas, modelos predictivos y estrategias inteligentes fortalecerá la toma de decisiones basada en resultados verificables [11]. A nivel académico, el proyecto ofrece un aporte relevante al evidenciar la aplicabilidad de la ingeniería de datos en el ámbito educativo, demostrando cómo las herramientas tecnológicas pueden contribuir directamente a la calidad y efectividad de la formación superior. Este sistema representa un avance significativo hacia la transformación digital en la gestión educativa, permitiendo a la universidad disponer de una plataforma sólida para el monitoreo, análisis y predicción del desempeño de sus estudiantes.

V. OBJETIVOS

A. Objetivo General

Desarrollo de un sistema de información para el análisis comparativo y predictivo de la evolución de competencias académicas entre las pruebas Saber 11 y Saber Pro de los estudiantes de la Universidad San Buenaventura.

B. Objetivos Específicos

- Identificar y consolidar los datos de las pruebas Saber 11 y Saber Pro de los estudiantes, para establecer una base comparativa de las competencias individuales y grupales.
- Analizar la relación entre las competencias iniciales en Saber 11 y los resultados finales en Saber Pro, empleando métricas estadísticas y modelos de correlación.
- Diseñar un modelo predictivo que estime la evolución de las competencias estudiantiles desde Saber 11 hasta Saber Pro, utilizando técnicas de estimación estadística.

VI. PROBLEMA DE INVESTIGACIÓN

A pesar de que el ICFES administra de forma sistemática las pruebas Saber 11 y Saber Pro, y de que ambos instrumentos evalúan competencias comparables en dos momentos del proceso formativo, la información que generan permanece desarticulada: los resultados de cada prueba se almacenan y analizan de manera independiente, sin un mecanismo que vincule el desempeño inicial de un estudiante con su desempeño final [26]. Esta desarticulación impide estimar cuánto del resultado en Saber Pro puede anticiparse a partir de las condiciones de entrada del estudiante [27] y, en consecuencia, dificulta separar el aporte propio de la institución —el valor agregado— [28] de aquello que ya venía determinado por su perfil académico y socioeconómico previo.

En el caso de la Universidad de San Buenaventura, esta limitación se traduce en la ausencia de un instrumento analítico que permita responder, con respaldo cuantitativo, preguntas centrales para la gestión académica: qué desempeño en Saber Pro cabe esperar de un estudiante dado su punto de partida en Saber 11, qué factores contextuales modulan esa relación [29] y en qué medida la trayectoria observada se aparta —favorable o desfavorablemente— de la esperada. Sin un sistema que modele explícitamente esta relación de entrada y salida, las decisiones sobre acompañamiento estudiantil, fortalecimiento curricular y asignación de recursos continúan tomándose sin una base predictiva sólida.

De lo anterior se desprende el problema que orienta esta investigación: la inexistencia, en la Universidad de San Buenaventura, de un sistema de información capaz de integrar los resultados de las pruebas Saber 11 y Saber Pro y de modelar predictivamente la evolución de las competencias académicas entre ambos momentos. En consecuencia, el presente trabajo se formula en torno a la siguiente pregunta de investigación:

¿En qué medida es posible estimar el desempeño de los estudiantes de la Universidad de San Buenaventura en las pruebas Saber Pro a partir de sus resultados en Saber 11 y de variables socioeconómicas y de contexto, de modo que el sistema permita cuantificar la evolución de sus competencias académicas?

VII. HIPÓTESIS

El desarrollo e implementación de un sistema de información analítico y predictivo basado en los resultados de las pruebas Saber 11 permitirá predecir los resultados de las pruebas Saber Pro con un nivel de precisión cercano al 70%, a partir de los puntajes obtenidos en Saber 11 y de factores socioeconómicos y académicos, evidenciando una mejora promedio del 10% en las competencias entre ambas pruebas.

VIII. MARCO REFERENCIAL

A. Marco Teórico

El presente estudio combina la teoría del aprendizaje basado en competencias, la analítica del aprendizaje y la minería de datos educativos, como enfoques que permiten comprender cómo los datos académicos pueden utilizarse para mejorar el desarrollo de competencias y la toma de decisiones en la educación superior. Desde la perspectiva del aprendizaje por competencias, el rendimiento académico no se mide únicamente por la acumulación de conocimientos, sino por la capacidad del estudiante para aplicar saberes en contextos reales. Según el estudio realizado por [11] en el año 2013, las competencias representan la integración entre el saber, el hacer y el ser, y constituyen la base para la evaluación educativa moderna. Este campo emergente permite a las instituciones identificar patrones de éxito, riesgo o mejora en el aprendizaje a partir de grandes volúmenes de información educativa. En este sentido, la incorporación de técnicas de minería de datos educativos fortalece la capacidad de generar modelos predictivos y diagnósticos de desempeño, transformando los registros académicos en conocimiento útil. De acuerdo con [12], el uso de herramientas analíticas permite tomar decisiones basadas en evidencia, potenciando la calidad educativa mediante la gestión del conocimiento institucional.

En un nivel teórico más amplio, la teoría sociocognitiva de Bandura (1977) y el constructivismo de Vygotsky (1978) sirven como base para comprender cómo el aprendizaje se desarrolla mediante la interacción entre el individuo, el entorno y los recursos educativos disponibles [30] [31]. Estas teorías sostienen que el aprendizaje es un proceso activo, social y contextual, lo cual respalda el enfoque del sistema de información propuesto: un entorno donde los datos no solo se recolectan, sino que se interpretan a la luz de las condiciones individuales y colectivas del estudiante. En conjunto, la investigación de este proyecto proporciona una visión integral que combina la medición objetiva del aprendizaje (competencias), la interpretación basada en datos (analítica y minería educativa) y la comprensión social del conocimiento (constructivismo). Con ello, se busca que el sistema de información propuesto no solo prediga el rendimiento entre las pruebas Saber 11 y Saber Pro, sino que también oriente estrategias institucionales para fortalecer el desarrollo de competencias y reducir brechas académicas.

B. Marco Conceptual

Explorando el contexto de la investigación en Colombia, la evaluación de las competencias que presenta un estudiante se estructura en torno a los instrumentos estandarizados diseñados por el Instituto Colombiano para la Evaluación de la Educación (ICFES). La prueba Saber 11, aplicada al finalizar la educación media o bachillerato, permite medir las habilidades y conocimientos que los estudiantes han adquirido en áreas como Lectura crítica, Matemáticas, Ciencias naturales,

Sociales y ciudadanas, e Inglés [5]. Por su parte, la prueba Saber Pro evalúa el desarrollo de competencias genéricas y específicas alcanzadas durante la formación universitaria, proporcionando un marco de referencia que funciona a nivel nacional para valorar la calidad del proceso formativo de las instituciones de educación superior [13]. Ambas pruebas, al ser de carácter obligatorio y comparables en el tiempo, constituyen una fuente de información esencial para estudiar la continuidad y/o evolución de las habilidades académicas a lo largo del proceso educativo.

Existe un fenómeno conocido como ‘‘valor agregado educativo’’, concepto introducido en la literatura de eficacia escolar por [32] (1971) y adoptado en Colombia por el Ministerio de Educación Nacional y el ICFES como indicador del progreso o ganancia en el nivel de competencias que experimenta el estudiante entre dos momentos de su trayectoria formativa, y es precisamente el análisis de los resultados obtenidos en estas pruebas el que permite comprender este valor agregado [33]. La investigación realizada en Colombia por [14], en la Universidad del Norte, plantea que este indicador permite estimar el aporte que realiza la institución al aprendizaje del estudiante, considerando su punto de partida y su contexto socioeconómico. Dicho valor no mide únicamente resultados finales, sino la diferencia entre el desempeño alcanzado y aquel que sería esperado según las condiciones iniciales.

La medición del valor agregado se apoya en modelos predictivos que estiman el puntaje esperado en Saber Pro a partir de variables como los resultados de Saber 11, los antecedentes académicos y los factores contextuales del estudiante. Por ejemplo, el estudio ‘‘Predicción rendimiento estudiantes pruebas Saber Pro en pandemia junto con las características socioeconómicas’’ propone el uso de algoritmos de minería de datos —como árboles de decisión y regresión logística— para generar anticipaciones al desempeño final; de esta forma, la diferencia entre el puntaje real y el valor pronosticado constituye una medida cuantitativa del valor agregado [15].

Es importante delimitar los factores a examinar; así, el modelo conceptual considera la relación entre tres grandes conjuntos de variables: las competencias iniciales, representadas por los puntajes en Saber 11; las competencias terminales, representadas por los puntajes en Saber Pro; y los factores socioeconómicos y de contexto que influyen en dicha relación. Se parte del supuesto de que las competencias evaluadas en Saber 11 constituyen la base cognitiva sobre la cual se desarrollan las competencias en la educación superior, por lo que un mejor desempeño en la prueba Saber 11 se asocia con un mayor potencial de aprendizaje y un mejor resultado en Saber Pro. Sin embargo, esta relación no se produce de manera aislada, sino que se ve mediada por condiciones socioeconómicas, contextuales e institucionales que moldean la trayectoria de cada estudiante.

Entre los factores contextuales más relevantes se encuentran el nivel socioeconómico, la escolaridad de los padres, el tipo de institución educativa de procedencia, el acceso a recursos tecnológicos y la localización geográfica del estudiante. Un entorno familiar con mayores recursos

educativos y económicos tiende a ofrecer más oportunidades de aprendizaje, lo que se traduce en mejores desempeños en las pruebas estandarizadas. De igual forma, los estudiantes provenientes de instituciones privadas o con acceso a herramientas tecnológicas suelen presentar mejores resultados en Saber 11 y, posteriormente, un progreso más sostenido durante su formación superior.

El proceso educativo universitario actúa como mediador entre las competencias iniciales y las finales. Dentro de este proceso intervienen factores ligados a la Institución de Educación Superior (IES) como la calidad del programa académico, la pertinencia del currículo, las estrategias pedagógicas implementadas, la disponibilidad de recursos tecnológicos y el desempeño académico del estudiante, medido mediante indicadores como el promedio acumulado (GPA) o el número de asignaturas reprobadas. Estos factores reflejan la capacidad de la institución para potenciar las competencias adquiridas en la educación media y transformarlas en habilidades profesionales de mayor complejidad. Cabe resaltar que las instituciones con procesos consolidados de acreditación y gestión de la calidad presentan un mayor valor agregado en las competencias evaluadas, lo que sugiere que la calidad institucional incide directamente en la evolución de las habilidades del estudiante [14].

En cuanto a los conceptos metodológicos del trabajo, la regresión lineal es uno de los modelos predictivos más utilizados en el aprendizaje automático y la estadística, cuyo objetivo es describir la relación entre una variable dependiente continua y una o más variables independientes mediante una función lineal. En su forma simple, busca minimizar la suma de los errores cuadráticos entre los valores observados y los estimados, lo que la convierte en una herramienta eficaz para evaluar tendencias entre factores como las competencias académicas iniciales y los resultados finales [16]. Este método resulta particularmente útil cuando se requiere interpretar el peso o la influencia de cada variable predictora en el resultado, permitiendo entender cómo ciertos indicadores de Saber 11 pueden anticipar el rendimiento en Saber Pro [16].

Los árboles de decisión representan un método no paramétrico que divide recursivamente el espacio de los datos en regiones homogéneas según los valores de las variables predictoras. Cada nodo de decisión contiene una regla condicional, y las hojas finales representan los valores de salida estimados. Su principal ventaja radica en la capacidad de manejar relaciones no lineales y de ofrecer una interpretación intuitiva mediante reglas “si-entonces” que facilitan la comprensión del modelo por parte de actores institucionales [17]. Además, pueden extenderse a técnicas como los bosques aleatorios (*Random Forests*) o los *Gradient Boosted Trees*, que mejoran su rendimiento reduciendo la varianza de los modelos individuales [17].

El algoritmo de los k vecinos más cercanos (KNN) se basa en la proximidad o similitud entre observaciones. Este enfoque asume que las instancias cercanas en el espacio de características tienden a compartir valores similares de la variable objetivo. Para una nueva muestra, el modelo calcula las distancias a todas las observaciones existentes y asigna la predicción en función del

promedio o la moda de los k vecinos más cercanos [18]. KNN no requiere un entrenamiento paramétrico complejo, lo que lo convierte en una técnica flexible y útil en contextos educativos donde el número de variables y patrones puede ser diverso [18].

Las redes neuronales artificiales (RNA), y en particular el perceptrón multicapa (*MLP*, por sus siglas en inglés), constituyen modelos de aprendizaje supervisado capaces de aproximar relaciones no lineales complejas entre las variables de entrada y la variable objetivo. Un *MLP* organiza el cálculo en capas sucesivas de neuronas: cada neurona combina linealmente las salidas de la capa anterior y aplica una función de activación no lineal —habitualmente la unidad lineal rectificada (ReLU)—, lo que permite a la red representar interacciones que un modelo lineal no captura. En problemas de regresión, la capa de salida emplea una activación lineal y el entrenamiento ajusta los pesos minimizando una función de pérdida, como el error cuadrático medio, mediante descenso de gradiente y retropropagación [34]. Su principal ventaja en este trabajo radica en la capacidad de modelar conjuntamente los distintos predictores cuando se dispone de un volumen de datos suficientemente grande, condición que se satisface en el conjunto emparejado utilizado.

Por su parte, las técnicas de segmentación o agrupamiento (*clustering*) permiten organizar a los estudiantes en grupos homogéneos según la similitud de su perfil de entrada, sin emplear la variable objetivo durante ese proceso. El algoritmo *K-means* es uno de los más difundidos: particiona las observaciones en K grupos minimizando la distancia de cada una al centro o centroide de su grupo [35]. Por sí mismo, el agrupamiento no realiza predicciones; para convertirlo en un estimador se adopta una estrategia en dos fases conocida como agrupar-y-predecir (*cluster-then-predict*): primero se forman los grupos a partir de los perfiles de entrada y, una vez constituidos, a cada grupo se le asigna una respuesta para la variable objetivo —el promedio de sus miembros o una regresión lineal local ajustada dentro del grupo—, que luego se aplica a cualquier estudiante nuevo según el grupo al que más se asemeje. Este enfoque parte del supuesto de que estudiantes con perfiles iniciales similares tienden a presentar desempeños futuros similares.

Dentro del proceso de evaluación de modelos predictivos, el Error Cuadrático Medio de la Raíz (RMSE, por sus siglas en inglés) es una métrica ampliamente empleada para medir la precisión del modelo. Se define como la raíz cuadrada de la media de los errores al cuadrado, proporcionando una medida del error promedio en las mismas unidades que la variable dependiente [19]. Cuanto menor sea el RMSE, mayor será la precisión del modelo. En contextos de predicción educativa, esta métrica permite cuantificar de forma directa la diferencia entre el desempeño real y el estimado de los estudiantes [19].

El coeficiente de determinación (R^2) complementa el RMSE al medir la proporción de la varianza total explicada por el modelo. Su valor varía entre 0 y 1, donde valores cercanos a 1 indican un ajuste adecuado del modelo y una alta capacidad explicativa. Este indicador es esencial para analizar la calidad de los modelos de regresión lineal y no lineal, pues permite estimar qué

tanto del rendimiento académico puede atribuirse a los factores considerados en el modelo [20].

El preprocesamiento de datos es una etapa crítica para garantizar la validez y la fiabilidad del análisis. Comprende tareas como la imputación de valores faltantes, la codificación de variables categóricas y la normalización de escalas. La literatura enfatiza que una depuración adecuada de los datos contribuye a mejorar el rendimiento de los algoritmos y reduce sesgos en los resultados [21]. En particular, el uso de bibliotecas como Pandas, NumPy y Scikit-learn de Python permite automatizar estos procesos, asegurando consistencia y reproducibilidad [21].

Dentro del preprocesamiento, la normalización de escalas merece una precisión, pues existen métodos con efectos distintos. La normalización Min-Max reescala cada variable a un rango acotado, habitualmente $[0, 1]$, mediante una transformación afín que preserva la forma de la distribución original. La estandarización (puntaje z), en cambio, centra cada variable en media cero y desviación unitaria, y resulta conveniente para el ajuste de modelos sensibles a la escala de las entradas [36].

En el contexto del aprendizaje automático aplicado a la educación, el campo de *Educational Data Mining* (EDM) ha demostrado que los algoritmos supervisados como la regresión, los árboles de decisión y KNN son útiles para predecir el rendimiento de los estudiantes y detectar factores de riesgo académico [22]. Diversos estudios han resaltado la importancia de combinar estos modelos con métricas de evaluación objetivas y sistemas de visualización interactivos para facilitar la interpretación de los resultados por parte de los tomadores de decisiones institucionales [22].

A partir de estos conceptos y criterios en conjunto, la visualización y los sistemas de información educativos permiten traducir los resultados de los modelos predictivos en herramientas accesibles para la gestión académica. Los tableros de control (*dashboards*) y reportes automatizados facilitan la comprensión de patrones de rendimiento, fomentando la toma de decisiones basada en datos dado que reflejan dinámicas y tendencias ocultas, que brindan mayor información y precisión al momento de tomar decisiones [23]. La implementación de un sistema de información predictivo y comparativo permitirá optimizar el análisis del desempeño académico institucional, fortaleciendo la planeación y las estrategias de mejora [23].

De este modo, se observa que la educación es un proceso acumulativo en el que las competencias previas, las condiciones contextuales y las oportunidades institucionales interactúan para definir el desarrollo académico del estudiante. Por ello, la comprensión de estas interrelaciones es esencial para diseñar estrategias de intervención educativa, orientar políticas institucionales y fortalecer los procesos de formación, evaluación y seguimiento de los resultados de aprendizaje.

C. Estado del Arte

En los últimos años, diversos trabajos en Colombia han explorado directamente la predicción del desempeño en Saber Pro y la relación entre Saber 11 y Saber Pro. En 2024, el estudio

realizado por [9] desarrolló un modelo descriptivo y predictivo para optimizar la mejora en las pruebas Saber Pro, empleando datos históricos y caracterización estudiantil para identificar los factores que más influyen en el rendimiento académico. Otro análisis, realizado por [24] en 2021, utilizó algoritmos como Naive Bayes y k -Nearest Neighbors para predecir resultados de Saber Pro, encontrando que variables como el nivel educativo de la madre, la composición familiar, la residencia y el equipamiento doméstico tienen peso significativo en el desempeño.

Asimismo, el estudio hecho por [10] en 2025 aplicó regresión logística multinomial para estimar niveles de desempeño de estudiantes universitarios en Saber Pro en función de variables académicas y contextuales. Por su parte, el trabajo desarrollado por [25] en 2022 generó metodologías longitudinales para medir valor agregado entre Saber 11 y Saber Pro, reconociendo la influencia de factores como la demanda institucional, el contexto geográfico y los mecanismos de selección. Estos estudios recientes muestran que ya existe evidencia concreta de que los datos generados con desempeños en Saber 11, combinados con variables adicionales de contexto y académicas, pueden alimentar modelos predictivos útiles, lo que refuerza la viabilidad del sistema propuesto y el objetivo de fortalecer competencias institucionales.

IX. METODOLOGÍA

El desarrollo metodológico se estructuró en siete fases sucesivas, desde la obtención de los datos hasta el despliegue del sistema de información. El proyecto se concibió como un sistema de valor agregado: la red neuronal opera como motor predictivo que estima el desempeño esperado en Saber Pro, y el valor agregado institucional se obtiene como la diferencia entre el desempeño observado y dicho desempeño esperado.

A. Recolección e integración de datos

Se emplearon los registros de las pruebas Saber 11 (2010–2024) y Saber Pro (2014–2023), alojados en una base de datos PostgreSQL compuesta por 25 tablas de resultados (quince de Saber 11 y diez de Saber Pro, una por año). La integración se resolvió en el motor de base de datos: se unificaron las tablas de cada examen y se cruzó cada estudiante de Saber Pro con su correspondiente de Saber 11 mediante una tabla de llaves, obteniendo aproximadamente 1 320 000 pares emparejados a partir de cerca de 6 050 000 registros de Saber 11 y 1 880 000 de Saber Pro. Este conjunto emparejado constituye la muestra efectiva del estudio. El procesamiento posterior se realizó en Python con las librerías PySpark, Pandas, NumPy, Scikit-learn y TensorFlow/Keras; dado que el volumen final cabe en memoria, no fue necesario recurrir a entornos de cómputo distribuido.

B. Depuración y tratamiento de registros atípicos

Durante el análisis se identificaron registros de puntajes considerados inusuales, caracterizados por presentar un valor de cero en los módulos. Estos registros se conservaron en la base de datos con el fin de preservar la integridad de la información original; sin embargo, no fueron tenidos en cuenta durante los análisis estadísticos ni durante el entrenamiento de los modelos, pues un valor de cero en un puntaje no representa un desempeño real y su inclusión distorsionaría las medidas descriptivas, las correlaciones y la actualización de los parámetros del modelo. El origen de estos registros se asocia a las pruebas Saber Pro anteriores al año 2016, periodo en el que se utilizaba un método de calificación distinto al vigente; por ello, dichos registros fueron excluidos del análisis, no de la base de datos, para no mezclar formatos de calificación incompatibles, decisión que constituye un supuesto metodológico adoptado durante la depuración. De manera análoga, se descartaron de los análisis las filas con datos ausentes en los módulos análogos que actúan como variables de entrada o de salida. En sentido contrario, se mantuvo una categoría “-A1” del módulo de Inglés: si bien el Marco Común Europeo de Referencia (MCER) clasifica la competencia en seis niveles (A1 a C2), el conjunto de datos incluye un nivel adicional “-A1” que corresponde a un dominio prácticamente nulo del idioma,

situación frecuente en la población colombiana; por su elevada frecuencia, excluir esta categoría habría sesgado el análisis del módulo, razón por la cual se conservó.

C. Correspondencia de competencias y cálculo del puntaje global

Dado que las competencias no reciben el mismo nombre en Saber 11 y en Saber Pro, se estableció una correspondencia de pares análogos que vincula los cuatro módulos comparables entre ambas pruebas (véase Tabla 1): la competencia lógico-cuantitativa, la lectora-comunicativa, la ciudadana-cívica y la de Inglés. El módulo de Ciencias Naturales de Saber 11 se excluyó del núcleo comparativo por carecer de análogo en Saber Pro. Respecto al puntaje global, la mayoría de los registros lo traían ya calculado por el ICFES; la excepción son los años 2010 a 2013 de Saber 11, para los cuales no existía un puntaje global dado que en ese periodo el ICFES no lo calculaba, situación que responde a un cambio histórico en la estructura del examen y no a una ausencia de datos. El ICFES obtiene el global de Saber 11 como un promedio ponderado de la siguiente forma:

$$\frac{(3 \cdot MA) + (3 \cdot LC) + (3 \cdot SC) + (3 \cdot CN) + (1 \cdot IN)}{13} \cdot 5$$

donde MA = puntaje matemáticas, LC = puntaje lectura crítica, SC = puntaje ciencias sociales/ciudadanas, CN = puntaje ciencias naturales y IN = puntaje inglés; mientras que el de Saber Pro lo calcula como un promedio simple tal que:

$$\frac{RC + CE + LC + CC + IN}{5}$$

donde RC = puntaje razonamiento cuantitativo, CE = puntaje comunicación escrita, LC = puntaje lectura crítica, CC = puntaje competencias ciudadanas y IN = puntaje inglés [37] [38]. El menor peso del Inglés en Saber 11 responde a un criterio de equidad: el nivel socioeconómico condiciona la calidad de la educación recibida y este efecto es especialmente marcado en Inglés, donde los estudiantes de instituciones privadas o de mayores recursos obtienen puntajes notablemente superiores. Sobre esta base, en el presente trabajo se calculó un puntaje global propio para ambas pruebas, replicando la lógica del ICFES pero considerando únicamente los cuatro módulos con análogo, tal que:

$$\frac{(3 \cdot MA) + (3 \cdot LC) + (3 \cdot SC) + (1 \cdot IN)}{10} \cdot 5$$

,

$$\frac{RC + LC + CC + IN}{4}$$

para Saber 11 y Saber Pro, respectivamente. Adicionalmente, se propone que el puntaje global de Saber Pro se calcule también como promedio ponderado con menor peso para el Inglés y no como promedio simple, dado que la asociación entre nivel socioeconómico y dominio del idioma se mantiene en la educación superior.

Saber 11	Saber Pro	Competencia general
punt_matematicas_norm	mod_razona_cuantitat_punt_norm	Competencia lógico-cuantitativa
punt_lenguaje_norm (2010–2013), punt_lectura_critica_norm (2014 en adelante)	mod_lectura_critica_punt_norm	Competencia lectora-comunicativa
punt_ciencias_sociales_norm (2010–2013), punt_sociales_ciudadanas_norm (2014 en adelante)	mod_competen_ciudadana_punt_norm	Competencia ciudadana-cívica
punt_ingles_norm	mod_ingles_punt_norm	Competencia en Inglés
punt_global_norm	punt_global_norm	Puntaje Global
punt_global_calc_norm	punt_global_calc_norm	Puntaje Global Calculado

Tabla 1: Tabla de correspondencia de pares análogos entre Saber 11 y Saber Pro.

D. Normalización y escalado

El ICFES no entrega los puntajes normalizados, sino en las escalas propias de cada prueba, que no son directamente comparables entre Saber 11 y Saber Pro. Por ello, durante el desarrollo del sistema se aplicó una normalización Min-Max al rango $[0, 1]$, con el fin de llevar ambos exámenes a una escala común que habilitara la comparación de competencias. Es preciso advertir que el ICFES reformó la metodología de la prueba Saber 11 en 2014; en consecuencia, los años anteriores no son comparables con los posteriores, tanto porque antes de esa fecha no existía un puntaje global como porque el método de calificación de los módulos específicos era distinto del actual. Esto significa que, aunque el rango de puntajes se mantenga semejante, los de 2010–2013 no son equiparables con los de 2014 en adelante. Aunque el ICFES administra pruebas desde mucho antes, el sistema recopila información de Saber 11 únicamente a partir de 2010. Pese a la diferencia señalada, los puntajes de 2010–2013 se normalizaron con el mismo método que los demás, lo cual se asume explícitamente como un supuesto metodológico. Por su parte, el vector de entrada de los modelos predictivos se estandarizó (puntaje z) antes del entrenamiento, ajustando los parámetros de escala y los valores de imputación de las variables socioeconómicas —por mediana— exclusivamente sobre el conjunto de entrenamiento, a fin de evitar la filtración de información hacia validación y prueba.

E. Partición temporal

De cara al entrenamiento de la RNA, La partición de los datos no se realizó de forma aleatoria sino por cohortes según el año de presentación de Saber 11: entrenamiento con las cohortes

2010–2016, validación con 2017 y prueba con 2018. Se excluyeron las cohortes de Saber 11 posteriores a 2018 por no contar aún con su correspondiente Saber Pro. Sobre el conjunto se calcularon medidas descriptivas y se analizó la correlación entre las competencias iniciales de Saber 11 y las finales de Saber Pro.

F. Sistema de formas y variables de entrada

La estimación se abordó bajo dos configuraciones de entrada, denominadas formas, con el fin de cuantificar el aporte del contexto socioeconómico. La Forma 1, que actúa como línea base, emplea únicamente los cuatro módulos análogos de Saber 11 —razonamiento cuantitativo, lectura crítica, competencias ciudadanas e inglés—; en los módulos de razonamiento cuantitativo y competencias ciudadanas se añadieron además tres variables temporales: el año de presentación de Saber 11, el de Saber Pro y la brecha en años entre ambas pruebas. La Forma 2 es una configuración ampliada de veinte variables, incorpora a los cuatro módulos un conjunto de ocho variables socioeconómicas, siete indicadores de ausencia y un indicador de institución objetivo, y prescinde de las variables temporales. Las ocho variables socioeconómicas provienen del registro de Saber 11 y describen el contexto del estudiante: el carácter bilingüe del colegio, su área de ubicación (urbana o rural), su naturaleza (oficial o privada), la jornada escolar, el género del estudiante, el estrato de la vivienda y el nivel educativo de la madre y del padre. Dado que algunas presentaban valores ausentes, se imputaron por la mediana calculada solo con el conjunto de entrenamiento y, por cada variable con ausencias apreciables, se construyó un indicador de ausencia: una variable booleana que toma el valor uno cuando el dato original faltaba y cero cuando estaba presente, de modo que el modelo pueda distinguir un valor imputado de uno real (siete en total, pues el género, con menos del cinco por ciento de ausencias, no requirió indicador). El indicador de institución objetivo es, a su vez, una variable booleana que señala si el estudiante presentó Saber Pro en la Universidad de San Buenaventura, lo que permite filtrar y comparar posteriormente el desempeño de la institución frente al total. El contraste entre ambas formas constituye en sí mismo un resultado, pues la diferencia de error entre la Forma 1 y la Forma 2 cuantifica el aporte del contexto socioeconómico a la estimación.

G. Arquitectura y entrenamiento del modelo de valor agregado

El motor predictivo del sistema es una red neuronal artificial de tipo perceptrón multicapa. En lugar de una sola red que estime los cuatro módulos a la vez, se entrenó una red independiente por cada competencia y por cada forma, de modo que cada una optimiza un único objetivo sin que el error de un módulo interfiera con el de los demás. Para separar las mejoras reales de diseño del ruido propio de la inicialización aleatoria, cada red se entrenó tres veces con semillas distintas

(42, 123y777) y la predicción definitiva de cada estudiante se obtiene como el promedio de las tres corridas; este promediado por conjunto (ensemble) reduce la varianza de la estimación sin alterar su sesgo, por lo que resulta más estable que cualquier corrida individual. Las métricas reportadas corresponden a dicho ensemble, recalculadas sobre el conjunto de prueba, y no al promedio de las métricas individuales, que subestimaría la ganancia del promediado. Todas las redes comparten la misma arquitectura, organizada en tres capas ocultas de tamaño decreciente. La primera capa, de 64 neuronas, aplica normalización por lotes y una activación lineal rectificada con fuga (LeakyReLU); la segunda, de 32 neuronas, emplea activación ReLU seguida de una regularización por abandono (dropout) del veinte por ciento; la tercera, de 16 neuronas, utiliza activación ReLU; y la capa de salida es lineal y de una sola neurona, que entrega el puntaje continuo del módulo. Los pesos se inicializan con el método de He y el entrenamiento se realiza con el optimizador Adam (tasa de aprendizaje inicial de 0,001) y la función de pérdida de error cuadrático medio, con lotes de 512 observaciones y un máximo de cien épocas. Para contener el sobreajuste se aplican detención temprana —que restaura los pesos del mejor estado observado sobre el conjunto de validación, con una paciencia de quince épocas— y reducción adaptativa de la tasa de aprendizaje cuando el desempeño deja de mejorar. El estado del generador aleatorio se reinicia antes de construir cada red, lo que garantiza inicializaciones reproducibles y comparables entre semillas. Por cada forma se ajustó una única estandarización, calculada solo con el conjunto de entrenamiento y compartida por las cuatro redes de esa forma; las variables temporales, cuando intervienen, se ubican al final del vector de entrada, de manera que los módulos que no las utilizan reciben exactamente las mismas columnas base ya estandarizadas, preservando la coherencia del puntaje global reconstruido a partir de los cuatro módulos. La configuración 'V3_5' es el resultado de una exploración por factores aislados: a partir de una arquitectura base se ensayó un cambio a la vez —ingeniería de variables, función de pérdida robusta, variables temporales y separación en modelos independientes— conservando únicamente los ajustes que mejoraron el desempeño de cada módulo y descartando los que no aportaron o lo deterioraron. De esa síntesis, la única especialización que permaneció fue la incorporación de tres variables temporales —el año de presentación de cada prueba y la brecha en años entre ambas— en los módulos de razonamiento cuantitativo y competencias ciudadanas de la Forma 1; los demás módulos, en ambas formas, emplean la configuración base con error cuadrático medio. Como modelos de referencia, frente a los cuales se contrasta la red, se construyeron una regresión lineal y un esquema de segmentación K-means bajo la estrategia agrupar-y-predecir descrita en el Marco Conceptual. La técnica de árboles de decisión, contemplada inicialmente, no se implementó y se plantea como trabajo futuro.

H. Evaluación y despliegue del sistema

El desempeño de los modelos se evaluó sobre el conjunto de prueba mediante el error absoluto medio (MAE), el error cuadrático medio de la raíz ($RMSE$) y el coeficiente de determinación (R^2) por competencia. El puntaje global predicho se reconstruyó por un camino explícito —desnormalización de cada módulo, aplicación de la fórmula de ponderación y nueva normalización del global—, y el valor agregado institucional se cuantificó por competencia y por año como la diferencia entre el desempeño observado y el esperado. Finalmente, los resultados se integraron en un sistema de información desarrollado con Dash sobre la base PostgreSQL, que incluye líneas de tendencia comparativas entre Saber 11 y Saber Pro para un mismo grupo de estudiantes y una matriz que cuantifica el aporte de la institución. El sistema se dispuso para su despliegue en un servidor Ubuntu mediante *Gunicorn*, *Nginx* y *systemd*. La población correspondió a los estudiantes de la Universidad de San Buenaventura que presentaron ambas pruebas, y la muestra al conjunto de pares efectivamente emparejados.

X. RESULTADOS

Los resultados se organizan en dos planos: la capacidad predictiva de los modelos sobre el conjunto de prueba y la cuantificación del valor agregado institucional por competencia y año.

A. Desempeño predictivo de los modelos

La Tabla 2 presenta el coeficiente de determinación (R^2) obtenido sobre el conjunto de prueba —la cohorte 2018— para los tres modelos en sus dos formas. La red neuronal alcanza la mayor capacidad explicativa en la mayoría de las competencias, con valores que oscilan entre 0,39 y 0,61; el error absoluto medio se mantuvo en el rango de 0,05 a 0,07 sobre la escala normalizada [0, 1]. La excepción es el módulo de Inglés, donde la regresión lineal iguala o supera ligeramente a la red ($R^2 \approx 0,624$ frente a 0,599–0,612), lo que indica que esa competencia se explica de forma relativamente adecuada mediante una relación lineal y no se beneficia tanto de un modelo de mayor complejidad. El esquema de segmentación *K-means* resultó el menos preciso, en especial en su variante de predicción por promedio del grupo y en la Forma 2.

Competencia	RNA F1	RNA F2	Reg. lineal F1	Reg. lineal F2	K-means F1	K-means F2
Lógico-cuantitativa	0,510	0,426	0,393	0,401	0,368	0,300
Lectora-comunicativa	0,397	0,406	0,383	0,381	0,378	0,337
Ciudadana-cívica	0,445	0,390	0,353	0,345	0,344	0,295
Inglés	0,599	0,612	0,624	0,624	0,600	0,536

Tabla 2: R^2 en el conjunto de prueba por modelo y competencia (Forma 1 / Forma 2).

Un hallazgo central es que la incorporación de variables socioeconómicas (Forma 2) no mejoró de manera significativa la capacidad predictiva de la red respecto de la configuración que solo emplea los puntajes de Saber 11 (Forma 1); de hecho, en las competencias lógico-cuantitativa y ciudadana-cívica el desempeño disminuyó (de 0,510 a 0,426 y de 0,445 a 0,390, respectivamente). El esquema de segmentación *K-means*, que selecciona internamente un número de grupos de 256, evidenció el mismo comportamiento de forma más acentuada, lo que sugiere que el contexto socioeconómico aporta información en esencia marginal una vez conocido el desempeño inicial del estudiante.

B. Valor agregado institucional

La Tabla 3 cuantifica el aporte de la institución por competencia y año, entendido como la diferencia entre el desempeño observado en Saber Pro y el esperado a partir de las condiciones de

entrada. Los valores son negativos en prácticamente todas las competencias y periodos, con la única excepción del Inglés entre 2016 y 2018. La magnitud del aporte negativo se profundiza de manera marcada a partir de 2019, alcanzando sus valores más bajos entre 2021 y 2023. La cercanía entre el puntaje global oficial y el global calculado en este trabajo confirma la validez del procedimiento de cálculo adoptado.

Año	Lógico-cuant.	Lectora-com.	Ciudadana	Inglés	Global	Global calc.
2016	-2,89	-1,76	-1,20	+0,25	-1,88	-1,58
2017	-2,33	-0,63	-2,69	+0,20	-1,64	-1,27
2018	-1,73	-1,17	-2,60	+0,16	-1,01	-0,58
2019	-4,31	-3,05	-4,57	-1,13	-3,08	-2,60
2020	-5,15	-3,24	-3,12	-1,48	-3,92	-2,85
2021	-7,05	-6,03	-6,47	-2,80	-6,11	-5,37
2022	-7,04	-5,44	-6,74	-2,54	-6,72	-5,33
2023	-7,76	-6,67	-8,35	-3,62	-6,67	-6,51

Tabla 3: Aporte institucional (valor agregado) por competencia y año.

XI. DISCUSIÓN

Los resultados obligan a contrastar de manera directa las dos afirmaciones de la hipótesis. La primera, que postulaba una precisión cercana al 70%, no se cumple cuando se operacionaliza como coeficiente de determinación: la mejor capacidad explicativa alcanzada es de 0,61 en Inglés, y el resto de competencias se sitúa entre 0,39 y 0,51. La segunda, que anticipaba una mejora promedio del 10% entre ambas pruebas, tampoco se sostiene: la cuantificación del valor agregado revela un aporte institucional negativo en casi todas las competencias y años, es decir, lo contrario a una mejora. Conviene precisar por qué un coeficiente de determinación moderado no constituye, en sí mismo, una falla del sistema, sino una consecuencia esperable del problema. Entre la presentación de Saber 11 y la de Saber Pro median alrededor de cinco años, durante los cuales ocurre precisamente aquello que el estudio busca medir: el efecto de la formación universitaria. La porción del desempeño en Saber Pro que no puede explicarse desde Saber 11 es, en buena parte, el valor agregado de la institución; si un modelo lograra explicar la totalidad de la varianza, ello implicaría que la universidad no aporta nada y que el resultado final ya estaba determinado por las condiciones de entrada. En este marco, una capacidad explicativa moderada es coherente con la naturaleza del fenómeno y se alinea con la literatura de minería de datos educativos, que reporta capacidades predictivas igualmente acotadas en problemas análogos. Por esta misma línea de razonamiento, el periodo temporal transcurrido entre la presentación de ambas pruebas constituye un intervalo de incertidumbre, donde el desarrollo académico de una persona no está condicionado únicamente por su proceso académico en la institución universitaria. La mejora o desmejora de las capacidades y competencias de un alumno están, en efecto, afectadas por la Institución de Educación Superior a la cual pertenece, sin embargo, de igual forma influyen una cantidad de parámetros ajenos a la universidad que no es posible prever en su totalidad y por tanto este estudio no contempla. Un alumno A podría mantener hábitos de lectura como actividad de ocio mientras que un alumno B no, este alumno B podría frecuentar actividades extracurriculares de estudio por el aspecto social (que fomentan la mejora de sus capacidades) mientras que un alumno C no; es este aspecto personal, e imprevisible en gran parte, que no se ve representado en la información recopilada en los datasets de estudio y por tanto genera una variabilidad en el modelo que implica una gran incertidumbre en el sistema al momento de intentar predecir puntajes de competencias. El segundo hallazgo relevante es que la incorporación de variables socioeconómicas no incrementó la capacidad predictiva, e incluso la redujo en dos competencias. Una explicación plausible es que el efecto del contexto socioeconómico ya se encuentra incorporado de manera implícita en los propios puntajes de Saber 11, de modo que añadir esas variables introduce más ruido que señal. Este comportamiento ilustra empíricamente el principio de la maldición de la dimensionalidad descrito por [39]: ampliar el vector de entrada de cuatro a veinte variables no se tradujo en una mejora, lo que sugiere que la

dimensionalidad adicional no estuvo acompañada de información discriminante nueva. El caso del Inglés merece atención particular, pues es la única competencia con valor agregado positivo en los primeros años y la única en la que un modelo lineal iguala a la red neuronal. Ambos hechos son consistentes entre sí y con la evidencia de que el dominio del idioma está fuertemente condicionado por el nivel socioeconómico: se trata de la competencia más predecible desde las condiciones de entrada y, a la vez, aquella en la que la institución parece incidir de forma más visible. Esta observación respalda la propuesta metodológica de calcular el puntaje global de Saber Pro como un promedio ponderado que asigne menor peso al Inglés, replicando el criterio de equidad que el ICFES aplica en Saber 11. Finalmente, el deterioro del valor agregado a partir de 2019 debe interpretarse con cautela: coincide con el periodo de la pandemia, que alteró las condiciones de formación y evaluación, por lo que su magnitud no es atribuible únicamente a factores institucionales. Asimismo, conviene recordar que la partición temporal de los datos (entrenar con cohortes pasadas y evaluar con una posterior) ofrece una estimación honesta, y por tanto más conservadora, del desempeño que la que arrojaría una partición aleatoria.

XII. CONCLUSIONES

El objetivo general del trabajo se cumplió: se desarrolló e implementó un sistema de información que integra a nivel individual los resultados de las pruebas Saber 11 y Saber Pro de la Universidad de San Buenaventura, estima el desempeño esperado mediante una red neuronal y cuantifica el valor agregado institucional por competencia y por año, poniendo esta información a disposición de los tomadores de decisiones a través de un tablero interactivo desplegable. No obstante, la hipótesis planteada no se confirma en ninguna de sus dos afirmaciones. La capacidad predictiva máxima alcanzada ($R^2 \approx 0,61$) no llega al umbral del 70% propuesto, y el análisis del valor agregado no evidencia una mejora promedio del 10%, sino un aporte institucional mayoritariamente negativo. Reportar este resultado con transparencia es, en sí mismo, una contribución: el sistema cumple su función analítica con independencia de que los datos confirmen o no la expectativa inicial. Entre los modelos evaluados, la red neuronal ofreció el mejor desempeño global, con una ventaja modesta pero consistente sobre la regresión lineal y la segmentación K-means, salvo en Inglés, donde la relación es esencialmente lineal. Se concluye además que las variables socioeconómicas consideradas no aportan capacidad predictiva adicional una vez conocidos los puntajes de Saber 11, hallazgo que tiene valor metodológico para futuros trabajos sobre la misma población. Por último, el aporte institucional negativo, lejos de invalidar el proyecto, constituye un insumo accionable: señala competencias y periodos en los que el desempeño observado quedó por debajo del esperado y orienta la atención hacia las áreas que requieren intervención. El valor de este trabajo reside, por tanto, en la herramienta construida y en la evidencia que produce, más que en la verificación de la hipótesis.

XIII. RECOMENDACIONES

A partir de los hallazgos se formulan las siguientes recomendaciones para trabajos futuros y para la operación del sistema. En primer lugar, se sugiere implementar y evaluar la técnica de árboles de decisión, contemplada inicialmente pero no desarrollada, así como sus extensiones de conjunto —bosques aleatorios y árboles potenciados por gradiente—, que podrían capturar interacciones no lineales no exploradas y servir como nuevo punto de comparación frente a la red neuronal. En segundo lugar, se recomienda adoptar el cálculo del puntaje global de Saber Pro como promedio ponderado con menor peso para el Inglés, en coherencia con el criterio de equidad del ICFES y con la evidencia de que esa competencia está fuertemente asociada al nivel socioeconómico. En tercer lugar, dado que la capacidad explicativa está acotada por la naturaleza del problema, se aconseja incorporar variables propias del proceso universitario —como el promedio acumulado o el número de asignaturas reprobadas— que podrían explicar una porción mayor de la varianza atribuible al valor agregado. En cuarto lugar, conviene avanzar hacia un modelado diferenciado por programa académico y por cohorte, que permita identificar fortalezas y debilidades específicas en lugar de un comportamiento institucional agregado. En quinto lugar, se recomienda estudiar de manera dedicada el deterioro del valor agregado posterior a 2019, controlando el efecto de la pandemia mediante líneas base ajustadas a ese periodo. Finalmente, en el plano operativo, se sugiere conservar como artefacto canónico la predicción promediada sobre múltiples semillas, reentrenar el sistema a medida que nuevas cohortes completen ambas pruebas y mantener actualizado el manual técnico de despliegue para garantizar la continuidad del servicio.

XIV. ANEXOS

A. Diccionario de datos

Descripción de las 25 tablas, nombres de columnas, las ocho variables socioeconómicas y los módulos por examen.

B. Manual técnico

Manual técnico de despliegue, alineado con las normas ISO aplicables.

C. Capturas del tablero interactivo





Fig. 1. Menú de login.






Fig. 4. Menú de comparativa para puntajes entre universidades.




Fig. 5. Menú para generar reportes en PDF.



Fig. 6. Tablas de la base de datos.

XV. REFERENCIAS

- [1] S. M. Chica Gómez, D. M. Galvis Gutiérrez y A. Ramírez Hassan, “Determinantes del rendimiento académico en Colombia. Pruebas ICFES-Saber 11o, 2009”, Revista Universidad EAFIT, vol. 46, n.º 160, págs. 48-72, 2010.
- [2] D. Buitrago Arria y L. C. Sánchez Garzón, “Un estudio de factores socio-económicos asociados al desempeño en el examen Saber 11 en Colombia”, Maestros & Pedagogía, vol. 6, n.º 2, págs. 8-31, 2024.
- [3] J. M. Lozano Hoyos, J. D. Padilla Gamarra y C. Á. Porto Candamil, “Factores claves que describen los resultados de Pruebas Saber 11 en el departamento del Atlántico usando técnicas de analítica de datos”, Tesis de Maestría, Universidad del Norte, Barranquilla, Colombia, 2022.
- [4] J. C. Miranda, Y. Chadid y F. Quintero, “Ingreso, clases sociales y Desigualdad educativa en Barranquilla: Colombia”, Ad-gnosis, vol. 7, n.º 7, pág. 8, 2018.
- [5] Icfes, “Informe nacional de resultados del examen Saber 11 2023”, Instituto Colombiano para la Evaluación de la Educación (Icfes), Bogotá, Colombia, inf. téc., mayo de 2024. [Internet]. Disponible en https://www.icfes.gov.co/wp-content/uploads/2025/04/Informe_Saber11_2023.pdf.
- [6] A. Sánchez Jabba, “Etnia y desempeño académico en Colombia”, Documentos de Trabajo Sobre Economía Regional y Urbana; No. 156, 2011.
- [7] L. J. Corsi García, M. C. García Buitrago, M. Jiménez Archila y J. P. Niño Garzón, “Factores asociados a desempeños destacados y no destacados en las pruebas Saber 11 (2009-2)”, Tesis de Maestría, Pontificia Universidad Javeriana, Bogotá, Colombia, 2012.
- [8] D. A. García Arango, M. A. Mejía Cardona y C. F. Henao Villa, “Pruebas Saber Pro y Saber 11: análisis de correlaciones aplicado a programas de ingeniería”, Asociación Colombiana de Facultades de Ingeniería (ACOFI Papers), págs. 1-10, 2021.
- [9] J. A. Mendieta López, “Modelo descriptivo y predictivo para optimizar la mejora en pruebas Saber Pro: un enfoque basado en datos históricos y caracterización estudiantil”, Tesis de Maestría, Universidad de Bogotá Jorge Tadeo Lozano, Bogotá, Colombia, 2024.
- [10] H. Granados López, “Modelado del desempeño en competencias pruebas Saber Pro: un enfoque multinomial”, Tesis de Maestría, Universidad Católica de Manizales, Manizales, Colombia, 2025.
- [11] S. Tobón Tobón, *Formación integral y competencias: pensamiento complejo, currículo, didáctica y evaluación*. Bogotá, Colombia: Ecoe ediciones, 2013.

-
- [12] C. Cobo Romaní y J. W. Moravec, *Aprendizaje invisible. Hacia una nueva ecología de la educación*. Publicacions i Edicions Universitat de Barcelona, 2011.
- [13] Icfes and Sapiencia, *Infographic Best Saber Pro*, Infografía en línea, 2022. [Internet]. Disponible en https://sapiencia.gov.co/wp-content/uploads/2022/12/infographic-best-saber-pro_anonymous.pdf.
- [14] M. Maestre Delgado, “El valor agregado como medida de la calidad educativa en instituciones de educación superior en Colombia”, Tesis de maestría, Universidad del Norte, Barranquilla, Colombia, 2022. [Internet]. Disponible en <https://manglar.uninorte.edu.co/handle/10584/11012>.
- [15] S. C. Vanegas Ayala, D. D. Leal Lara y J. Barón Velandia, “Predicción rendimiento estudiantes pruebas Saber Pro en pandemia junto con las características socioeconómicas”, Tecnología, Investigación y Academia (TIA), vol. 9, n.º 2, págs. 5-16, jun. de 2022, issn: 2344-8288.
- [16] Google Developers, *Linear Regression | Machine Learning Crash Course*, Google Developers, ago. de 2025. [Internet]. Disponible en <https://developers.google.com/machine-learning/crash-course/linear-regression>.
- [17] I. D. Mienye y N. Jere, “A Survey of Decision Trees: Concepts, Algorithms and Applications”, IEEE Access, vol. 11, págs. 120 192-120 208, 2023.
- [18] N. Bhatia y V. Kumar, “Survey of Nearest Neighbor Techniques”, arXiv preprint arXiv:1007.0085, 2010.
- [19] T. O. Hodson, “Root-mean-square error (RMSE) or mean absolute error (MAE): when to use them or not”, Geoscientific Model Development, vol. 15, págs. 5481-5487, 2022. DOI: 10.5194/gmd-15-5481-2022
- [20] J. Chicco y G. Jurman, “The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation”, PeerJ Computer Science, 2021.
- [21] J. Han, M. Kamber y J. Pei, *Data Mining: Concepts and Techniques*, 4th. Elsevier, 2022.
- [22] Ö. Özyurt, H. Özyurt y D. Mishra, “Uncovering the Educational Data Mining Landscape and Future Perspective: A Comprehensive Analysis”, IEEE Access, vol. 11, págs. 120 192-120 208, 2023.
- [23] R. Alamri y B. Alharbi, “Explainable Student Performance Prediction Models: A Systematic Review”, IEEE Access, vol. 9, págs. 33 132-33 143, 2021.

-
- [24] D. E. Martínez Cervera, “Modelo de pronóstico en la educación superior en pruebas específicas de ingeniería, licenciatura y pensamiento científico matemático en Saber Pro aplicando Machine Learning”, Tesis de Maestría, Universidad Distrital Francisco José de Caldas, Bogotá, Colombia, 2021.
- [25] D. Ramírez del Río y J. Guerrero Erazo, “Índice de desempeño relativo pruebas Saber 11–Saber Pro”, Encuentro Internacional de Educación en Ingeniería, 2022.
- [26] J. Bogoya y J. Bogoya, “Un modelo matemático para el valor académico agregado: Caso de la educación superior en Colombia”, *Ingeniería e Investigación*, vol. 33, n.º 2, págs. 76-81, 2013.
- [27] J. D. Bogoya, J. M. Bogoya y A. J. Peñuela, “Value-added in higher education: ordinary least squares and quantile regression for a Colombian case”, *Ingeniería e Investigación*, vol. 37, n.º 3, págs. 30-36, 2017.
- [28] F. A. Mendoza-Lozano, C. M. Pico-Bonilla, D. Bacca-Morales y M. A. Cano-Niño, “Valor agregado en la educación superior colombiana: una revisión de la contribución de los programas y las instituciones a la calidad educativa”, *Revista colombiana de educación*, n.º 99, 2026.
- [29] R. Rodríguez-Revilla y R.-D. Vallejo-Molina, “Valor agregado y las competencias genéricas de los estudiantes de educación superior en Colombia”, *Revista iberoamericana de educación superior*, vol. 13, n.º 36, págs. 44-62, 2022.
- [30] A. Bandura, “Self-efficacy: toward a unifying theory of behavioral change”, *Psychological review*, vol. 84, n.º 2, pág. 191, 1977.
- [31] M. Cole, *Mind in society: Development of higher psychological processes*. Harvard university press, 1978.
- [32] E. Hanushek, “Teacher characteristics and gains in student achievement: Estimation using micro data”, *The American Economic Review*, vol. 61, n.º 2, págs. 280-288, 1971.
- [33] Instituto Colombiano para la Evaluación de la Educación (ICFES), “Medición de los efectos de la educación superior en Colombia sobre el aprendizaje estudiantil: Informe técnico”, Instituto Colombiano para la Evaluación de la Educación (ICFES), Bogotá D.C., Colombia, inf. téc., abr. de 2021, [En línea; accedido jun. 2026]. [Internet]. Disponible en <https://www.icfes.gov.co/wp-content/uploads/2024/11/Informe-tecnico-1.pdf>.
- [34] I. Goodfellow, Y. Bengio, A. Courville e Y. Bengio, *Deep learning*. MIT press Cambridge, 2016, vol. 1.
- [35] J. B. McQueen, “Some methods of classification and analysis of multivariate observations”, en *Proc. of 5th Berkeley Symposium on Math. Stat. and Prob.*, 1967, págs. 281-297.

- [36] W. J. Gil González, J. J. Mora Flórez y S. M. Pérez Londoño, “Análisis del procesamiento de los datos de entrada para un localizador de fallas en sistemas de distribución”, *Tecnura*, vol. 18, n.º 41, págs. 64-75, 2014.
- [37] Instituto Colombiano para la Evaluación de la Educación, “Ficha metodológica de la operación estadística: Medición de la Calidad de la Educación a partir de los exámenes Saber (MCEAES)”, Subdirección de Estadísticas, ICFES, Bogotá, Colombia, Documento metodológico PYC-GU009, Versión 002, ago. de 2022. [Consultado: 27 de jun. de 2025]. [Internet]. Disponible en https://www.icfes.gov.co/wp-content/uploads/2024/11/FICHA_METODOLOGICA_OE.pdf.
- [38] Ministerio de Educación Nacional, “Indicadores de aprendizaje: Estadísticas e indicadores de educación preescolar, básica y media”, Portal SINEB, Oficina Asesora de Planeación y Finanzas, Ministerio de Educación Nacional, Bogotá, Colombia, Ficha de indicadores, 2023, Sistema de Información Nacional de Educación Básica y Media (SINEB). [Consultado: 27 de jun. de 2025]. [Internet]. Disponible en https://portalsineb.mineduacion.gov.co/1782/articles-412165_aprendizaje_00_2023.pdf.
- [39] M. Verleysen y D. François, “The curse of dimensionality in data mining and time series prediction”, en *International work-conference on artificial neural networks*, Springer, 2005, págs. 758-770.