

Desarrollo de un sistema de información para el análisis comparativo y predictivo de la evolución de competencias académicas entre las pruebas Saber 11 y Saber Pro de los estudiantes de la Universidad San Buenaventura

Jostin Alejandro Gómez Restrepo
Samuel Giraldo Duque

Trabajo de Grado presentado para optar al título de Ing. Datos y software

Asesor:
Jairo Ivan Coy Coy



Universidad de San Buenaventura
Facultad de Ingenierías (Bello)
Ingeniería Datos y software
Bello, Colombia
2026

Citar/How to cite	Gonzáles Mejía et al . [1]
Referencia/Reference	[1] J. Gómez Restrepo S. Giraldo Duque . “Desarrollo de un sistema de información para el análisis comparativo y predictivo de la evolución de competencias académicas entre las pruebas Saber 11 y Saber Pro de los estudiantes de la Universidad San Buenaventura ”, Trabajo de grado profesional , Ingeniería Datos y software , Universidad de San Buenaventura Bello, Colombia , 2026 .
Estilo/Style: IEEE (2014)	



En convenio con la Universidad (nombre y logo pequeño de la institución).
 Seleccione posgrado USB Colombia (A-Z), Cohorte X.
 Grupo de Investigación (SIGLA).
 Línea de investigación en.



Biblioteca Digital (Repositorio)
www.bibliotecadigital.usb.edu.co

Bibliotecas Universidad de San Buenaventura

Biblioteca Fray Alberto Montealegre O.F.M. - Bogotá.
 Biblioteca Fray Arturo Calle Restrepo O.F.M. - Medellín, Bello, Armenia, Ibagué.
 Departamento de Biblioteca - Cali.
 Biblioteca Central Fray Antonio de Marchena – Cartagena.

Universidad de San Buenaventura Colombia - www.usb.edu.co

Bogotá - www.usbbog.edu.co

Medellín - www.usbmed.edu.co

Cali - www.usbcali.edu.co

Cartagena - www.usbctg.edu.co

Editorial Bonaventuriana - www.editorialbonaventuriana.usb.edu.co

Revistas científicas – www.revistas.usb.edu.co

Dedicatoria

Texto de dedicatoria centrado.

Agradecimientos

Texto de agradecimientos centrado.

TABLA DE CONTENIDO

RESUMEN	7
ABSTRACT	8
I INTRODUCCIÓN	9
II PLANTEAMIENTO DEL PROBLEMA	10
III ANTECEDENTES	11
IV JUSTIFICACIÓN	13
V OBJETIVOS	14
A Objetivo General	14
B Objetivos Específicos	14
VI PROBLEMA DE INVESTIGACIÓN	15
VII HIPÓTESIS	16
VIII MARCO REFERENCIAL	17
A Marco Teórico	17
B Marco Conceptual	17
C Estado del Arte	21
IX METODOLOGÍA	22
X RESULTADOS	23
XI DISCUSIÓN	24
XII CONCLUSIONES	25
XIII RECOMENDACIONES	26
XIV ANEXOS	27
XV REFERENCIAS	28

LISTA DE TABLAS

LISTA DE FIGURAS

RESUMEN

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Palabras clave — lorem, lorem, lorem

ABSTRACT

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Keywords — lorem, lorem, lorem

I. INTRODUCCIÓN

La calidad de la educación superior en Colombia constituye un tema de creciente interés institucional y académico, especialmente en lo que respecta a la medición objetiva del desarrollo de competencias a lo largo del proceso formativo. En este contexto, el Instituto Colombiano para la Evaluación de la Educación (ICFES) administra dos instrumentos estandarizados de gran relevancia: la prueba Saber 11, aplicada al finalizar la educación media, y la prueba Saber Pro, aplicada al término de la formación universitaria. Ambas pruebas permiten evaluar habilidades cognitivas y competencias en distintos momentos del ciclo educativo, lo que las convierte en una fuente de información valiosa para estudiar la evolución académica del estudiante. Sin embargo, a pesar de la riqueza informativa que ofrecen estos instrumentos, son pocas las instituciones de educación superior que han aprovechado sistemáticamente los datos generados por ambas pruebas para construir modelos analíticos que permitan comparar el desempeño inicial y final de sus estudiantes, identificar tendencias de crecimiento o estancamiento, y orientar estrategias educativas basadas en evidencia. La Universidad de San Buenaventura no es ajena a esta situación, lo que representa una oportunidad significativa para transformar datos académicos históricos en conocimiento institucional útil. Ante esta necesidad, el presente trabajo de grado propone el desarrollo de un sistema de información predictivo y comparativo que examine la evolución de las competencias académicas de los estudiantes desde las pruebas Saber 11 hasta las Saber Pro. Para ello, se integrará información proveniente de ambas pruebas junto con variables contextuales y socioeconómicas relevantes, con el fin de construir modelos estadísticos y de aprendizaje automático que estimen el desempeño esperado y permitan cuantificar el valor agregado que la institución aporta al proceso formativo de sus estudiantes. Desde el campo de la ingeniería de datos, este proyecto representa una aplicación concreta de técnicas de minería de datos educativos (*Educational Data Mining*, EDM), análisis estadístico y visualización interactiva al ámbito de la gestión académica universitaria, y la integración de modelos basados en sistemas inteligentes. El uso de algoritmos como la regresión lineal, los árboles de decisión y el método de los k vecinos más cercanos (KNN) permitirá construir modelos robustos de predicción, mientras que tableros de control (*dashboards*) facilitarán la interpretación de resultados por parte de los tomadores de decisiones institucionales.

II. PLANTEAMIENTO DEL PROBLEMA

El seguimiento del progreso académico de los estudiantes a lo largo de su formación universitaria constituye una herramienta clave para medir la calidad educativa y orientar estrategias de mejora continua. Sin embargo, existe una oportunidad de mejora basada en los datos que cada universidad recolecta de las pruebas Saber 11 y Saber Pro que no es comúnmente aprovechada, y que consiste en tomar toda esta información y transformarla en decisiones de negocio que se reflejen en mejores resultados académicos en los estudiantes. Esta situación surge dado que la mayoría de las instituciones de educación superior no disponen de sistemas que integren y analicen y se alíe con instituciones escolares que les proporcione información sobre los resultados de las pruebas saber 11 recientes. de manera estructurada la información proveniente de las pruebas ~~Saber 11 y Saber Pro~~. A su vez, esta falta de integración impide realizar análisis comparativos que permitan evaluar la evolución de las competencias adquiridas durante el proceso de formación [8]. En el caso de la Universidad San Buenaventura, donde todavía ~~no se aprovecha~~ ^{se cuenta con} esta falencia ~~como~~ ^{se muestra como} una oportunidad de mejora, contar con un sistema de información que relacione los resultados de ambas pruebas ~~facilita~~ ^{facilitando} la identificación de patrones de aprendizaje, fortalezas institucionales y áreas de oportunidad para cada programa académico [9]. **La ausencia de este tipo de herramientas limita la capacidad de realizar predicciones sobre el rendimiento futuro de los estudiantes y restringe la generación de estrategias pedagógicas basadas en evidencia** [5]. Por lo tanto, ^{se presenta} surge la necesidad de desarrollar un sistema que ~~no solo~~ ^{permite} consolide los datos de las pruebas Saber, ~~sino que también~~ incorpore técnicas estadísticas y modelos predictivos que ~~permitan~~ ^{permitiendo} anticipar la fluctuación de las competencias académicas a lo largo del proceso educativo.

III. ANTECEDENTES

La literatura colombiana ha aportado abundantes evidencias sobre cuáles son los factores estructurales y contextuales que inciden en los puntajes de las pruebas Saber 11, lo que permite fundamentar qué debe capturar un sistema de información que busque realizar un análisis comparativo y predictivo con robustez. Uno de los estudios más citados es [1], ~~de S. Chica Gómez et al.~~, donde mediante un modelo Logit Ordenado generalizado se encontraron impactos positivos y significativos de variables como nivel de ingreso del hogar, escolaridad de los padres, tipo de jornada escolar y naturaleza del colegio (oficial vs. no oficial) sobre los puntajes en matemáticas y lenguaje. ^{El estudio de} También, el artículo [2], ~~de D. Buitrago Ariza et al.~~, encontró que los puntajes bajos se asocian sistemáticamente con carencia de recursos educativos, bajo nivel educativo de los padres y condiciones de vida menos favorables, mientras que los puntajes altos se relacionan con mayores ingresos y mejores entornos familiares. En el Atlántico, ~~se realizó~~ la investigación [3], ~~de J. Lozano Hoyos et al.~~, donde se aplicaron análisis demográficos, sociales y económicos para identificar variables determinantes del rendimiento en Saber 11, tales como el acceso a internet, características del colegio y variables socioeconómicas del estudiante. Otro estudio regional, [4], ^{realizado por} ~~de I. Bonilla et al.~~, encontró que el ingreso del hogar, el estrato socioeconómico y la educación de los padres tienen efectos estadísticamente significativos sobre el puntaje en Saber 11, y que la educación de los padres contribuye de forma similar y consistente al rendimiento. ^{académico del hijo o individuo a cargo} Adicionalmente, el informe nacional del ICFES del año 2023, [5], presenta análisis de efectos marginales en modelos estadísticos que muestran cómo factores económicos, familiares y escolares inciden en los resultados del examen Saber 11 a nivel nacional, incluyendo variables como la condición de población víctima del conflicto armado, lo que permite dimensionar desigualdades territoriales y sociales. Por su parte, [6], ~~de A. Sánchez Jabbá~~, ^{cuáles?} documenta que los estudiantes pertenecientes a etnias obtienen en promedio puntajes inferiores, y que aunque parte de esa brecha se explica por características observables (familiares, institucionales y sociales), otra parte se debe a factores no observados, lo que implica que el sistema debe contemplar variables latentes o de contexto para capturar esta variación. ^{el estudio realizado por} Finalmente, [7], ~~de L. Corsi García et al.~~, estudia múltiples grupos de variables independientes —demográficas, socioeconómicas, familiares, escolares e institucionales— ^{zona y condición de trabajo,} ~~y encuentra que trabajar~~, pertenecer a una etnia, la pérdida de grados, el tipo de colegio, la jornada escolar y el acceso a internet son determinantes significativos del desempeño destacado frente al no destacado. Estos antecedentes muestran que los factores que consistentemente aparecen asociados al rendimiento en Saber 11 incluyen: nivel socioeconómico, ^{económicos} ingreso del hogar, escolaridad de los padres, tipo de colegio (oficial/privado), jornada escolar, acceso a recursos como internet o computadores, etnia, pérdida de grados, así como diferencias regionales y contextuales. Para el sistema propuesto, esto implica que debe

diseñarse para recolectar, limpiar e integrar estas variables, asegurar que los datos sean representativos (territorialidad, diversidad de programas, etc.) e incorporar métodos de modelado que permitan comparar subgrupos, estimar efectos marginales y posiblemente identificar variables no observadas o proxies que reflejen el contexto institucional. De esta manera, se podrán lograr predicciones útiles y, sobre todo, ^{crear y diseñar} ~~informar~~ estrategias institucionales orientadas a fortalecer las competencias académicas de los estudiantes.

IV. JUSTIFICACIÓN

La implementación de un sistema de información predictivo y comparativo permitirá optimizar el análisis del desempeño académico institucional [10]. Este proyecto no solo busca integrar la información proveniente de las pruebas Saber 11 y Saber Pro, sino también generar una herramienta que apoye la evaluación de la evolución formativa del estudiante desde su ingreso hasta la culminación de su carrera. Con este desarrollo, la Universidad San Buenaventura podrá identificar tendencias de crecimiento o estancamiento en las competencias, determinar qué factores inciden en el desempeño académico y orientar sus estrategias educativas hacia una mejora continua. Adicionalmente, el uso de técnicas estadísticas y modelos predictivos ^{y estrategias inteligentes} fortalecerá la toma de decisiones basada en resultados verificables [11]. A nivel académico, el proyecto ofrece un aporte relevante al evidenciar la aplicabilidad de la ingeniería de datos en el ámbito educativo, demostrando cómo las herramientas tecnológicas pueden contribuir directamente a la calidad y efectividad de la formación superior. Este sistema representa un avance significativo hacia la transformación digital en la gestión educativa, permitiendo a la universidad disponer de una plataforma sólida para el monitoreo, análisis y predicción del desempeño de sus estudiantes.

V. OBJETIVOS

A. Objetivo General

Desarrollo de un sistema de información para el análisis comparativo y predictivo de la evolución de competencias académicas entre las pruebas Saber 11 y Saber Pro de los estudiantes de la Universidad San Buenaventura.

Desarrollar un modelo analítico y predictivo que examine la evolución de las competencias de los estudiantes desde las pruebas Saber 11 hasta las Saber Pro, utilizando técnicas estadísticas para estimar el desempeño final a partir de las competencias iniciales.

↑ Especifico

B. Objetivos Específicos

- Identificar y consolidar los datos de las pruebas Saber 11 y Saber Pro de los estudiantes, para establecer una base comparativa de las competencias individuales y grupales.
- Analizar la relación entre las competencias iniciales en Saber 11 y los resultados finales en Saber Pro, empleando métricas estadísticas y modelos de correlación.
- Diseñar un modelo predictivo que estime la evolución de las competencias estudiantiles desde Saber 11 hasta Saber Pro, utilizando técnicas de estimación estadística.

VI. PROBLEMA DE INVESTIGACIÓN

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

¿Que sucedió con el problema de investigación?

Demuestra originalidad

Identificar el vacío : Contexto

⇒ Este item debe tener referencias bibliográficas.

VII. HIPÓTESIS

El desarrollo e implementación de un sistema de información analítico y predictivo basado en los resultados de las pruebas Saber 11 permitirá predecir los resultados de las pruebas Saber Pro con un nivel de precisión cercano al 70%, a partir de los puntajes obtenidos en Saber 11 y de factores socioeconómicos y académicos, evidenciando una mejora promedio del 10% en las competencias entre ambas pruebas.

¿Cuenta con las estrategias y mecanismos integrados para soportar esta hipótesis?
→ La hipótesis está bien planteada es sólida y muy precisa.

VIII. MARCO REFERENCIAL

A. Marco Teórico

El presente estudio ~~se apoya en un marco teórico~~ que combina la teoría del aprendizaje basado en competencias, la analítica del aprendizaje y la minería de datos educativos, como enfoques que permiten comprender cómo los datos académicos pueden utilizarse para mejorar el desarrollo de competencias y la toma de decisiones en la educación superior. Desde la perspectiva del aprendizaje por competencias, el rendimiento académico no se mide únicamente por la acumulación de conocimientos, sino por la capacidad del estudiante para aplicar saberes en contextos reales. Según ~~Tobón~~, las competencias representan la integración entre el saber, el hacer y el ser, y constituyen la base para la evaluación educativa moderna [11]. Este campo emergente permite a las instituciones identificar patrones de éxito, riesgo o mejora en el aprendizaje a partir de grandes volúmenes de información educativa. En este sentido, la incorporación de técnicas de minería de datos educativos fortalece la capacidad de generar modelos predictivos y diagnósticos de desempeño, transformando los registros académicos en conocimiento útil. De acuerdo con ~~Cobo y Moravec~~, el uso de herramientas analíticas permite tomar decisiones basadas en evidencia, potenciando la calidad educativa mediante la gestión del conocimiento institucional [12].

En un nivel teórico más amplio, la teoría sociocognitiva de Bandura y el constructivismo de Vygotsky sirven como base para comprender cómo el aprendizaje se desarrolla mediante la interacción entre el individuo, el entorno y los recursos educativos disponibles. Estas teorías sostienen que el aprendizaje es un proceso activo, social y contextual, lo cual respalda el enfoque del sistema de información propuesto: un entorno donde los datos no solo se recolectan, sino que se interpretan a la luz de las condiciones individuales y colectivas del estudiante. En conjunto, ~~este marco teórico~~ proporciona una visión integral que combina la medición objetiva del aprendizaje (competencias), la interpretación basada en datos (analítica y minería educativa) y la comprensión social del conocimiento (constructivismo). Con ello, se busca que el sistema de información propuesto no solo prediga el rendimiento entre las pruebas Saber 11 y Saber Pro, sino que también oriente estrategias institucionales para fortalecer el desarrollo de competencias y reducir brechas académicas.

B. Marco Conceptual

Explorando el contexto de la investigación en Colombia, la evaluación de las competencias que presenta un estudiante se estructura en torno a los instrumentos estandarizados diseñados por el Instituto Colombiano para la Evaluación de la Educación (ICFES). La prueba Saber 11, aplicada al finalizar la educación media o bachillerato, permite medir las habilidades y conocimientos que los estudiantes han adquirido en áreas como Lectura crítica, Matemáticas, Ciencias naturales,

Sociales y ciudadanas, e Inglés [5]. Por su parte, la prueba Saber Pro evalúa el desarrollo de competencias genéricas y específicas alcanzadas durante la formación universitaria, proporcionando un marco de referencia que funciona a nivel nacional para valorar la calidad del proceso formativo de las instituciones de educación superior [13]. Ambas pruebas, al ser de carácter obligatorio y comparables en el tiempo, constituyen una fuente de información esencial para estudiar la continuidad y/o evolución de las habilidades académicas a lo largo del proceso educativo.

Existe un fenómeno conocido como ^{¿Quién lo mide?} “valor agregado educativo”, entendido como el progreso o ganancia en el nivel de competencias que experimenta el estudiante entre dos momentos de su trayectoria formativa, y es precisamente el análisis de los resultados obtenidos en estas pruebas el que permite comprender este valor agregado. ^{La investigación realizada en Colombia} El artículo ^{Por} “El valor agregado como medida de la ^{en} calidad educativa en instituciones de educación superior en Colombia” [14], de la Universidad del Norte, plantea que este indicador permite estimar el aporte que realiza la institución al aprendizaje del estudiante, considerando su punto de partida y su contexto socioeconómico. Dicho valor no mide únicamente resultados finales, sino la diferencia entre el desempeño alcanzado y aquel que sería esperado según las condiciones iniciales.

La medición del valor agregado se apoya en modelos predictivos que estiman el puntaje esperado en Saber Pro a partir de variables como los resultados de Saber 11, los antecedentes académicos y los factores contextuales del estudiante. Por ejemplo, el estudio “Predicción rendimiento estudiantes pruebas Saber Pro en pandemia junto con las características socioeconómicas” propone el uso de algoritmos de minería de datos —como árboles de decisión y regresión logística— para generar anticipaciones al desempeño final; de esta forma, la diferencia entre el puntaje real y el valor pronosticado constituye una medida cuantitativa del valor agregado [15].

Es importante delimitar los factores a examinar; así, el modelo conceptual considera la relación entre tres grandes conjuntos de variables: las competencias iniciales, representadas por los puntajes en Saber 11; las competencias terminales, representadas por los puntajes en Saber Pro; y los factores socioeconómicos y de contexto que influyen en dicha relación. Se parte del supuesto de que las competencias evaluadas en Saber 11 constituyen la base cognitiva sobre la cual se desarrollan las competencias en la educación superior, por lo que un mejor desempeño en la prueba Saber 11 se asocia con un mayor potencial de aprendizaje y un mejor resultado en Saber Pro. Sin embargo, esta relación no se produce de manera aislada, sino que se ve mediada por condiciones socioeconómicas, contextuales e institucionales que moldean la trayectoria de cada estudiante.

Entre los factores contextuales más relevantes se encuentran el nivel socioeconómico, la escolaridad de los padres, el tipo de institución educativa de procedencia, el acceso a recursos tecnológicos y la localización geográfica del estudiante. Un entorno familiar con mayores recursos educativos y económicos tiende a ofrecer más oportunidades de aprendizaje, lo que se traduce en

mejores desempeños en las pruebas estandarizadas. De igual forma, los estudiantes provenientes de instituciones privadas o con acceso a herramientas tecnológicas suelen presentar mejores resultados en Saber 11 y, posteriormente, un progreso más sostenido durante su formación superior.

El proceso educativo universitario actúa como mediador entre las competencias iniciales y las finales. Dentro de este proceso intervienen factores ligados a la Institución de Educación Superior (IES) como la calidad del programa académico, la pertinencia del currículo, las estrategias pedagógicas implementadas, la disponibilidad de recursos tecnológicos y el desempeño académico del estudiante, medido mediante indicadores como el promedio acumulado (GPA) o el número de asignaturas reprobadas. Estos factores reflejan la capacidad de la institución para potenciar las competencias adquiridas en la educación media y transformarlas en habilidades profesionales de mayor complejidad. Cabe resaltar que las instituciones con procesos consolidados de acreditación y gestión de la calidad presentan un mayor valor agregado en las competencias evaluadas, lo que sugiere que la calidad institucional incide directamente en la evolución de las habilidades del estudiante [14].

En cuanto a los conceptos metodológicos del trabajo, la regresión lineal es uno de los modelos predictivos más utilizados en el aprendizaje automático y la estadística, cuyo objetivo es describir la relación entre una variable dependiente continua y una o más variables independientes mediante una función lineal. En su forma simple, busca minimizar la suma de los errores cuadráticos entre los valores observados y los estimados, lo que la convierte en una herramienta eficaz para evaluar tendencias entre factores como las competencias académicas iniciales y los resultados finales [16]. Este método resulta particularmente útil cuando se requiere interpretar el peso o la influencia de cada variable predictora en el resultado, permitiendo entender cómo ciertos indicadores de Saber 11 pueden anticipar el rendimiento en Saber Pro [16].

Los árboles de decisión representan un método no paramétrico que divide recursivamente el espacio de los datos en regiones homogéneas según los valores de las variables predictoras. Cada nodo de decisión contiene una regla condicional, y las hojas finales representan los valores de salida estimados. Su principal ventaja radica en la capacidad de manejar relaciones no lineales y de ofrecer una interpretación intuitiva mediante reglas “si-entonces” que facilitan la comprensión del modelo por parte de actores institucionales [17]. Además, pueden extenderse a técnicas como los bosques aleatorios (*Random Forests*) o los *Gradient Boosted Trees*, que mejoran su rendimiento reduciendo la varianza de los modelos individuales [17].

El algoritmo de los k vecinos más cercanos (KNN) se basa en la proximidad o similitud entre observaciones. Este enfoque asume que las instancias cercanas en el espacio de características tienden a compartir valores similares de la variable objetivo. Para una nueva muestra, el modelo calcula las distancias a todas las observaciones existentes y asigna la predicción en función del promedio o la moda de los k vecinos más cercanos [18]. KNN no requiere un entrenamiento

paramétrico complejo, lo que lo convierte en una técnica flexible y útil en contextos educativos donde el número de variables y patrones puede ser diverso [18].

Dentro del proceso de evaluación de modelos predictivos, el Error Cuadrático Medio de la Raíz (RMSE, por sus siglas en inglés) es una métrica ampliamente empleada para medir la precisión del modelo. Se define como la raíz cuadrada de la media de los errores al cuadrado, proporcionando una medida del error promedio en las mismas unidades que la variable dependiente [19]. Cuanto menor sea el RMSE, mayor será la precisión del modelo. En contextos de predicción educativa, esta métrica permite **cuantificar de forma directa la diferencia entre el desempeño real y el estimado de los estudiantes** [19].

El coeficiente de determinación (R^2) complementa el RMSE al medir la proporción de la varianza total explicada por el modelo. Su valor varía entre 0 y 1, donde valores cercanos a 1 indican un ajuste adecuado del modelo y una alta capacidad explicativa. Este indicador es esencial para analizar la calidad de los modelos de regresión lineal y no lineal, pues permite estimar qué tanto del rendimiento académico puede atribuirse a los factores considerados en el modelo [20].

El preprocesamiento de datos es una etapa crítica para garantizar la validez y la fiabilidad del análisis. Comprende tareas como **la imputación de valores faltantes**, la **codificación de variables categóricas** y **la normalización de escalas**. La literatura enfatiza que una depuración adecuada de los datos contribuye a mejorar el rendimiento de los algoritmos y reduce sesgos en los resultados [21]. En particular, el uso de bibliotecas como Pandas, NumPy y Scikit-learn ~~en~~ Python permite automatizar estos procesos, asegurando consistencia y reproducibilidad [21].

En el contexto del aprendizaje automático aplicado a la educación, el campo de *Educational Data Mining* (EDM) ha demostrado que los algoritmos supervisados como la regresión, los árboles de decisión y KNN son útiles para predecir el rendimiento de los estudiantes y detectar factores de riesgo académico [22]. Diversos estudios han resaltado la importancia de combinar estos modelos con métricas de evaluación objetivas y sistemas de visualización interactivos para facilitar la interpretación de los resultados por parte de los tomadores de decisiones institucionales [22].

A partir de estos conceptos y criterios en conjunto,
~~Finalmente,~~ la visualización y los sistemas de información educativos permiten traducir los resultados de los modelos predictivos en herramientas accesibles para la gestión académica. Los tableros de control (*dashboards*) y reportes automatizados facilitan la comprensión de patrones de reflejan dinámicas y tendencias ocultas, que brindan mayor información y precisión al momento de tomar decisiones rendimiento, fomentando la toma de decisiones basada en datos [23]. La implementación de un sistema de información predictivo y comparativo permitirá optimizar el análisis del desempeño académico institucional, fortaleciendo la planeación y las estrategias de mejora [23].

De este modo, se observa que la educación es un proceso acumulativo en el que las competencias previas, las condiciones contextuales y las oportunidades institucionales interactúan para definir el desarrollo académico del estudiante. Por ello, la comprensión de estas interrelaciones es esencial para diseñar estrategias de intervención educativa, orientar políticas institucionales y

fortalecer los procesos de formación, evaluación y seguimiento de los resultados de aprendizaje.

C. Estado del Arte

En los últimos años, diversos trabajos en Colombia han explorado directamente la predicción del desempeño en Saber Pro y la relación entre Saber 11 y Saber Pro. En 2024, ~~J. Mendieta López~~^{el estudio realizado por} [9] desarrolló un modelo descriptivo y predictivo para optimizar la mejora en las pruebas Saber Pro, empleando datos históricos y caracterización estudiantil para identificar los factores que más influyen en el rendimiento académico. Otro análisis, ~~el de D. Martínez Cervera~~^{realizado por E 245} en 2021 [24], utilizó algoritmos como Naive Bayes y k -Nearest Neighbors para predecir resultados de Saber Pro, encontrando que variables como el nivel educativo de la madre, la composición familiar, la residencia y el equipamiento doméstico tienen peso significativo en el desempeño.

Asimismo, el estudio ~~de H. Granados López~~^{hecho por [10]} en 2025 [10] aplicó regresión logística multinomial para estimar niveles de desempeño de estudiantes universitarios en Saber Pro en función de variables académicas y contextuales. Por su parte, el trabajo ~~de D. Ramírez del Río~~^{desarrollado por [25] en} ~~del~~ 2022 [25] generó metodologías longitudinales para medir valor agregado entre Saber 11 y Saber Pro, reconociendo la influencia de factores como la demanda institucional, el contexto geográfico y los mecanismos de selección. Estos estudios recientes muestran que ya existe evidencia concreta de que los datos generados con desempeños en Saber 11, combinados con variables adicionales de contexto y académicas, pueden alimentar modelos predictivos útiles, lo que refuerza la viabilidad del sistema propuesto y el objetivo de fortalecer competencias institucionales.

Hablar de los técnicas de segmentación de datos
Hablar del principio de dimensionalidad.
Hablar del proceso de normalización ¿cual
tipo de trabajo o cuales?

IX. METODOLOGÍA

El proceso metodológico inicia con la recolección de datos institucionales correspondientes a registros de las pruebas Saber 11 y Saber Pro, que serán suministrados por el docente encargado. Posteriormente, se realiza una fase de depuración, limpieza y normalización de los datos por medio del uso de lenguajes de programación como Python y R, junto con librerías especializadas en análisis de datos como Pandas, NumPy y Scikit-learn, que permiten automatizar el manejo de datos faltantes y la estandarización de variables, garantizando su calidad y coherencia. Una vez estructurada la base de información, se desarrollará un análisis estadístico que incluirá el cálculo de medidas descriptivas como promedios, varianzas y desviaciones estándar, además de la aplicación de técnicas de correlación que permitan medir el grado de relación entre las competencias iniciales evaluadas en Saber 11 y las competencias finales evaluadas en Saber Pro.

A partir de los resultados de este análisis, se procederá con la construcción de un modelo predictivo basado en técnicas de aprendizaje automático, tales como la regresión lineal, los árboles de decisión o los algoritmos de vecinos más cercanos (KNN). Se escogen estos métodos porque permiten abordar distintos tipos de relaciones entre las variables: la regresión lineal facilita la identificación de tendencias y dependencias entre los factores académicos y socioeconómicos; los árboles de decisión ofrecen interpretabilidad y capacidad para manejar datos heterogéneos o no lineales; y el algoritmo KNN resulta útil para detectar similitudes entre estudiantes con características y desempeños afines. Este modelo buscará estimar el desempeño de los estudiantes en la prueba Saber Pro a partir de los resultados obtenidos en Saber 11, junto con variables adicionales relacionadas con su contexto socioeconómico y académico.

La validación del modelo se llevará a cabo mediante métricas como el error cuadrático medio (RMSE) y el coeficiente de determinación (R^2), con el propósito de evaluar su precisión y capacidad explicativa. Finalmente, los resultados obtenidos se integrarán en un sistema de información diseñado para la consulta, análisis y visualización de los datos, el cual incluirá paneles interactivos, reportes automatizados y herramientas gráficas que faciliten la interpretación de resultados. Este sistema servirá como una plataforma de apoyo para la toma de decisiones institucionales orientadas al fortalecimiento de las competencias académicas y al diseño de estrategias basadas en evidencia.

La población del estudio estará compuesta por los estudiantes de la Universidad San Buenaventura que hayan presentado ambas pruebas, mientras que la muestra se seleccionará en función de la disponibilidad y completitud de los datos, procurando que incluya representaciones de diferentes programas académicos y contextos socioeconómicos.

Se recomienda generar un diagrama que muestre cada uno de los componentes de la metodología.

Segmentos de la metodología de los elementos y fases de la metodología →

- 1 - se realizó...
- 2 - se continuó...
- n - ... hasta el último.

X. RESULTADOS

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

XI. DISCUSIÓN

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

XII. CONCLUSIONES

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

XIII. RECOMENDACIONES

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

XIV. ANEXOS

XV. REFERENCIAS

- [1] S. M. Chica Gómez, D. M. Galvis Gutiérrez y A. Ramírez Hassan, “Determinantes del rendimiento académico en Colombia. Pruebas ICFES-Saber 11o, 2009”, Revista Universidad EAFIT, vol. 46, n.º 160, págs. 48-72, 2010.
- [2] D. Buitrago Arria y L. C. Sánchez Garzón, “Un estudio de factores socio-económicos asociados al desempeño en el examen Saber 11 en Colombia”, Maestros & Pedagogía, vol. 6, n.º 2, págs. 8-31, 2024.
- [3] J. M. Lozano Hoyos, J. D. Padilla Gamarra y C. Á. Porto Candamil, “Factores claves que describen los resultados de Pruebas Saber 11 en el departamento del Atlántico usando técnicas de analítica de datos”, Tesis de Maestría, Universidad del Norte, Barranquilla, Colombia, 2022.
- [4] J. C. Miranda, Y. Chadid y F. Quintero, “Ingreso, clases sociales y Desigualdad educativa en Barranquilla: Colombia”, Ad-gnosis, vol. 7, n.º 7, pág. 8, 2018.
- [5] Icfes, “Informe nacional de resultados del examen Saber 11 2023”, Instituto Colombiano para la Evaluación de la Educación (Icfes), Bogotá, Colombia, inf. téc., mayo de 2024. [Internet]. Disponible en https://www.icfes.gov.co/wp-content/uploads/2025/04/Informe_Saber11_2023.pdf.
- [6] A. Sánchez Jabba, “Etnia y desempeño académico en Colombia”, Documentos de Trabajo Sobre Economía Regional y Urbana; No. 156, 2011.
- [7] L. J. Corsi García, M. C. García Buitrago, M. Jiménez Archila y J. P. Niño Garzón, “Factores asociados a desempeños destacados y no destacados en las pruebas Saber 11 (2009-2)”, Tesis de Maestría, Pontificia Universidad Javeriana, Bogotá, Colombia, 2012.
- [8] D. A. García Arango, M. A. Mejía Cardona y C. F. Henao Villa, “Pruebas Saber Pro y Saber 11: análisis de correlaciones aplicado a programas de ingeniería”, Asociación Colombiana de Facultades de Ingeniería (ACOFI Papers), págs. 1-10, 2021.
- [9] J. A. Mendieta López, “Modelo descriptivo y predictivo para optimizar la mejora en pruebas Saber Pro: un enfoque basado en datos históricos y caracterización estudiantil”, Tesis de Maestría, Universidad de Bogotá Jorge Tadeo Lozano, Bogotá, Colombia, 2024.
- [10] H. Granados López, “Modelado del desempeño en competencias pruebas Saber Pro: un enfoque multinomial”, Tesis de Maestría, Universidad Católica de Manizales, Manizales, Colombia, 2025.
- [11] S. Tobón Tobón, *Formación integral y competencias: pensamiento complejo, currículo, didáctica y evaluación*. Bogotá, Colombia: Ecoe ediciones, 2013.

- [12] C. Cobo Romaní y J. W. Moravec, *Aprendizaje invisible. Hacia una nueva ecología de la educación*. Publicacions i Edicions Universitat de Barcelona, 2011.
- [13] Icfes and Sapiencia, *Infographic Best Saber Pro*, Infografía en línea, 2022. [Internet]. Disponible en https://sapiencia.gov.co/wp-content/uploads/2022/12/infographic-best-saber-pro_anonymous.pdf.
- [14] M. Maestre Delgado, “El valor agregado como medida de la calidad educativa en instituciones de educación superior en Colombia”, Tesis de maestría, Universidad del Norte, Barranquilla, Colombia, 2022. [Internet]. Disponible en <https://manglar.uninorte.edu.co/handle/10584/11012>.
- [15] S. C. Vanegas Ayala, D. D. Leal Lara y J. Barón Velandia, “Predicción rendimiento estudiantes pruebas Saber Pro en pandemia junto con las características socioeconómicas”, Tecnología, Investigación y Academia (TIA), vol. 9, n.º 2, págs. 5-16, jun. de 2022, issn: 2344-8288.
- [16] Google Developers, *Linear Regression | Machine Learning Crash Course*, Google Developers, ago. de 2025. [Internet]. Disponible en <https://developers.google.com/machine-learning/crash-course/linear-regression>.
- [17] I. D. Mienye y N. Jere, “A Survey of Decision Trees: Concepts, Algorithms and Applications”, IEEE Access, vol. 11, págs. 120 192-120 208, 2023.
- [18] N. Bhatia y V. Kumar, “Survey of Nearest Neighbor Techniques”, arXiv preprint arXiv:1007.0085, 2010.
- [19] T. O. Hodson, “Root-mean-square error (RMSE) or mean absolute error (MAE): when to use them or not”, Geoscientific Model Development, vol. 15, págs. 5481-5487, 2022. DOI: 10.5194/gmd-15-5481-2022
- [20] J. Chicco y G. Jurman, “The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation”, PeerJ Computer Science, 2021.
- [21] J. Han, M. Kamber y J. Pei, *Data Mining: Concepts and Techniques*, 4th. Elsevier, 2022.
- [22] Ö. Özyurt, H. Özyurt y D. Mishra, “Uncovering the Educational Data Mining Landscape and Future Perspective: A Comprehensive Analysis”, IEEE Access, vol. 11, págs. 120 192-120 208, 2023.
- [23] R. Alamri y B. Alharbi, “Explainable Student Performance Prediction Models: A Systematic Review”, IEEE Access, vol. 9, págs. 33 132-33 143, 2021.

- [24] D. E. Martínez Cervera, “Modelo de pronóstico en la educación superior en pruebas específicas de ingeniería, licenciatura y pensamiento científico matemático en Saber Pro aplicando Machine Learning”, Tesis de Maestría, Universidad Distrital Francisco José de Caldas, Bogotá, Colombia, 2021.
- [25] D. Ramírez del Río y J. Guerrero Erazo, “Índice de desempeño relativo pruebas Saber 11–Saber Pro”, Encuentro Internacional de Educación en Ingeniería, 2022.